SVEUČILIŠTE U SPLITU

FAKULTET ELEKTROTEHNIKE, STROJARSTVA I BRODOGRADNJE

ZAVRŠNI RAD

METODE VIŠEKRITERIJSKOG ODLUČIVANJA U KRIZNOM UPRAVLJANJU

Tin Šolić

Split, rujan 2026.

SVEUČILIŠTE U SPLITU
FAKULTET ELEKTROTEHNIKE, STROJARSTVA I BRODOGRADNJE

Sveučilišni prijediplomski studij: **Računarstvo**

Smjer/Usmjerenje: /

Oznaka programa: 120

Akademska godina: 2025./2026.

Ime i prezime: **TIN ŠOLIĆ**

JMBAG: 0023161512

ZADATAK ZAVRŠNOG RADA

Naslov: **Metode višekriterijskog odlučivanja u kriznom upravljanju**

Zadatak: Detaljno proučiti i usporediti najčešće korištene metode više-kriterijskog odlučivanja (eng. Multi-Criteria Decision Making, MCDM) koje se mogu primijeniti u rješavanju problema hitne evakuacije u okviru civilne zaštite, posebno u situacijama kao što su potresi, poplave ili požari, uz podršku metoda umjetne inteligencije. Fokus će biti na analizi ključnih MCDM metoda poput AHP, VIKOR i TOPSIS, s posebnim naglaskom na njihovu primjenu u kriznom upravljanju. Rad će obuhvatiti teorijsku podlogu svake metode, koherentnu analizu njihovih prednosti i ograničenja, te procjenu njihove učinkovitosti u dinamičnim uvjetima kada su odluke hitne i moraju simultano uzeti u obzir različite kriterije poput sigurnosti, brzine evakuacije, pristupačnosti terena i dostupnosti resursa.

Datum obrane: 08.09.2026.

Mentor:

izv. prof. dr. sc. Maja Braović

Komentor:

univ. mag. ing. comp. Ena Sarajlić

IZJAVA

Ovom izjavom potvrđujem da sam završni rad s naslovom „**Metode višekriterijskog odlučivanja u kriznom upravljanju**“ pod mentorstvom izv. prof. dr. sc. Maje Braović pisao samostalno, primijenivši znanja i vještine stečene tijekom studiranja na Fakultetu elektrotehnike, strojarstva i brodogradnje, kao i metodologiju znanstvenoistraživačkog rada te uz korištenje literature koja je navedena u radu. Spoznaje, stavove, zaključke, teorije i zakonitosti drugih autora koje sam izravno ili parafrazirajući naveo u završnom radu citirao sam i povezao s korištenim bibliografskim jedinicama.



Student
Tin Šolić

SADRŽAJ

1 UVOD 1

2 KRIZNO UPRAVLJANJE KAO TEMELJ DONOŠENJA ODLUKA 4
2.1 Suvremeno sigurnosno okruženje 4
2.2 Sustav kriznog upravljanja 5
2.3 Životni ciklus kriznog upravljanja 6

3 METODE VIŠEKRITERIJSKOG ODLUČIVANJA 8
3.1 Osnovni koncepti višekriterijskog odlučivanja 8
3.2 AHP 9
3.2.1 Hijerarhijska struktura AHP metode 10
3.2.2 Parne usporedbe i Saatyjeva skala 11
3.2.3 Matematički model AHP metode 12
3.2.4 Konzistentnost usporedbi 15
3.2.5 Primjena AHP metode u sustavima kriznog upravljanja te njezine prednosti i ograničenja 17
3.3 VIKOR 18
3.3.1 Načelo rada VIKOR metode 19
3.3.2 Matematički model VIKOR metode 20
3.3.3 Normalizacija kriterijskih vrijednosti 23
3.3.4 Izračun pokazatelja S, R i Q 25
3.3.5 Primjena VIKOR metode u kriznom upravljanju 26
3.3.6 Prednosti i ograničenja VIKOR metode 27
3.4 TOPSIS 28
3.4.1 Načela rada TOPSIS metode 29
3.4.2 Matematički model TOPSIS metode 29
3.4.3 Normalizacija matrice odlučivanja 31
3.4.4 Ponderirana normalizirana matrica 33
3.4.5 Određivanje idealnog i anti-idealnog rješenja 35
3.4.6 Izračun udaljenosti od idealnog i anti-idealnog rješenja 37
3.4.7 Određivanje koeficijenta relativne bliskosti idealnom rješenju i konačno rangiranje 40
3.4.8 Primjena TOPSIS metode u kriznom upravljanju 41
3.4.9 Prednosti i ograničenja TOPSIS metode 41

4 Eksperimentalna primjena i usporedba MCDM metoda 43
4.1 Eksperimentalno okruženje 43
4.1.1 Instalacija i konfiguracija okruženja 44
4.1.2 Postavke i konfiguracija simulacijskog scenarija 46
4.1.3 Arhitektura i implementacija razvijenog agenta 52
4.2 Primjena MCDM metoda u razvijenom agentu 54
4.2.1 Odabir MCDM metoda 55
4.2.2 Definicija alternativa i kriterija 56
4.2.3 Formiranje matrice odlučivanja 59
4.2.4 Primjena SAW metode 62
4.2.5 Implementacija metode TOPSIS 64
4.2.6 Implementacija metode VIKOR 65
4.3 Eksperimentalna metodologija 69
4.3.1 Eksperimentalni uvjeti 69

4.3.2 Provedba eksperimenata ... 70
4.3.1 Prikupljanje i zapis rezultata ... 71
4.3.2 Obrada rezultata i metrike evaluacije ... 72
4.4 Rezultati eksperimentalnog istraživanja ... 73
4.4.1 Ponašanje agenta tijekom simulacije ... 73
4.4.2 Dinamika MCDM odluka ... 75
4.4.3 Rezultati izvođenja ... 76
4.4.4 Usporedba MCDM metoda ... 78
4.5 Rasprava ... 79
4.5.1 Analiza dobivenih rezultata ... 79
4.5.2 Ograničenja eksperimentalnog pristupa ... 79
4.5.3 Mogućnost primjene na krizno upravljanje ... 80
4.5.4 Smjerovi daljnjeg razvoja sustava ... 80
5 ZAKLJUČAK ... 82
LITERATURA ... 85
PRILOZI ... 88
Kazalo slika, tablica i kodova ... 88
Popis oznaka i kratica ... 90
SAŽETAK I KLJUČNE RIJEČI ... 93
ABSTRACT AND KEYWORDS ... 94
IZJAVA O KORIŠTENJU UMJETNE INTELIGENCIJE ... 95

1 UVOD

Odluka o evakuaciji tijekom krizne situacije – bila to potres, poplava, požar, teroristički napad ili bilo koji drugi događaj koji ugrožava veći broj ljudi – donosi se u vremenskom okviru od nekoliko minuta, često i sekundi, na temelju informacija koje su gotovo uvijek nepotpune, kontradiktorne ili zastarjele u trenutku kada stignu do donositelja odluke. Neovisno o tome je li donositelj odluke operativni centar civilne zaštite, vatrogasno zapovjedništvo, policijska koordinacija ili neko drugo tijelo nadležno za upravljanje krizom, struktura problema ostaje ista: potrebno je istovremeno procijeniti sigurnost pojedinih evakuacijskih ruta, vrijeme potrebno za izvlačenje stanovništva, stanje i prohodnost terena te uskladiti sve to s realnom raspoloživošću vozila, opreme i ljudi [1]. Problem nije samo u broju kriterija nego u tome što oni sustavno nisu usklađeni jedni s drugima: najkraća ruta rijetko je i najsigurnija, a resursi potrebni za brzu intervenciju često fizički nisu tamo gdje bi bili najkorisniji [2]. Standardni operativni postupci, temeljeni na unaprijed pripremljenim scenarijima specifičnim za pojedinu vrstu opasnosti, u pravilu ne uspijevaju obuhvatiti kombinatoriku stvarne situacije kada se više kriznih žarišta razvija paralelno, kada se priroda opasnosti mijenja tijekom same intervencije (primjerice, požar koji uzrokuje strukturalni kolaps) ili kada se ulazni podaci mijenjaju brže nego što ih čovjek stigne obraditi. Upravo zato što je struktura problema ista bez obzira na uzrok krize, ovaj rad ne promatra evakuaciju kao skup zasebnih, disciplinarno odvojenih scenarija (protupožarna evakuacija, protupoplavna evakuacija itd.), nego kao jedinstvenu klasu problema odlučivanja za koju se može razviti jedan opći sustav podrške, primjenjiv neovisno o tipu opasnosti koja ga je pokrenula.

Metode višekriterijskog odlučivanja (eng. *Multi-Criteria Decision Making - MCDM*) rješavaju upravo taj tip problema – formalizaciju odluke kada postoji više alternativa koje treba rangirati prema više, često proturječnih, kriterija, bez obzira na prirodu krize koja te alternative generira [3]. U fokus se stavljaju tri metode koje su u literaturi o kriznom upravljanju dokumentirane najčešće: AHP, TOPSIS i VIKOR [4]. Te tri metode nisu međusobno zamjenjive, nego rješavaju različite dijelove istog problema. AHP (eng. *Analytic Hierarchy Process*), koju je 1980. godine razvio Thomas Saaty, koristi se za strukturiranje problema kroz hijerarhijsku dekompoziciju kriterija i sustav parnih usporedbi, iz čega se dobivaju numeričke težine kriterija uz mjerljivu provjeru dosljednosti prosudbe (eng. *consistency ratio*) – pri čemu se hijerarhija kriterija može redefinirati ovisno o vrsti krize, dok metodološki okvir ostaje isti [5]. TOPSIS

rangira alternativne odluke prema njihovoj geometrijskoj udaljenosti od idealnog i anti-idealnog rješenja, što ga čini računalno jednostavnim i pogodnim za brzu primjenu u vremenski kritičnim situacijama, ali osjetljivim na način normalizacije podataka [6]. VIKOR uvodi kompromisno rangiranje koje eksplicitno balansira maksimizaciju grupne koristi i minimizaciju individualnog „žaljenja“ najgore rangirane alternative po pojedinom kriteriju – svojstvo osobito relevantno kada nijedna alternativa nije objektivno najbolja po svim kriterijima, nego je potrebno pronaći prihvatljiv kompromis, što je čest slučaj kod odluka koje uključuju izravan rizik po ljudski život [7]. U ovom završnom radu bit će uspoređen matematički aparat sve tri metode, njihova osjetljivost na promjenu težina i ulaznih podataka, računalna zahtjevnost te dokumentirani slučajevi primjene u različitim tipovima kriznih situacija.

Preostali dio rada strukturiran je u četiri poglavlja. Drugo poglavlje uvodi krizno upravljanje kao teorijski okvir rada: opisuje suvremeno sigurnosno okruženje u kojem se krizne situacije javljaju, strukturu sustava kriznog upravljanja te njegov životni ciklus kroz faze ublažavanja rizika, pripreme, odgovora i oporavka. Treće poglavlje detaljno obrađuje same MCDM metode – AHP, VIKOR i TOPSIS – kroz njihov matematički aparat, postupak izračuna i ilustrativne primjere primjene na problem odabira evakuacijske rute. Četvrto poglavlje prenosi te metode u eksperimentalni kontekst: opisuje SC2LE (StarCraft II Learning Environment) [8], okruženje koje je razvio DeepMind [9] u suradnji s Blizzard Entertainmentom [10], način na koji je agent, čije je odlučivanje temeljeno na MCDM metodama, u njemu implementiran, te rezultate usporedbe ponašanja pojedinih metoda unutar simulacije. Podržano učenje (eng. *reinforcement learning*) pritom se spominje kao širi kontekst iz kojeg SC2LE dolazi i kao mogući smjer nadogradnje ovakvog sustava, a ne kao metoda korištena u samom eksperimentu – uz jasno navedeno ograničenje da igra ne reproducira fizikalnu ni socijalnu dinamiku stvarne evakuacije, nego služi kao poligon za testiranje algoritamskog ponašanja pod strukturno sličnim ograničenjima. Peto, zaključno poglavlje sažima dobivene rezultate, ograničenja provedenog istraživanja te moguće smjerove daljnjeg razvoja prema dinamičkom sustavu potpore odlučivanju.

Rad se na kraju osvrće i na sigurnosnu dimenziju primjene ovakvih sustava, promatranu na razini sustava, a ne kroz tehničke pojedinosti. Prekomjerno oslanjanje operatera na automatiziranu preporuku bez kritičke provjere (eng. *automation bias*) predstavlja poseban rizik u odlukama koje izravno ugrožavaju ljudski život [11], zbog čega rad zagovara

zadržavanje čovjeka u petlji odlučivanja (eng. *human-in-the-loop*) i transparentnost sustava, a ne potpunu automatizaciju procesa [12].

Cilj rada je stoga pružiti utemeljenu i provjerljivu usporedbu metoda AHP, VIKOR i TOPSIS te ocijeniti njihovu prikladnost za buduću integraciju s algoritmima podržanog učenja u općem, tipski neovisnom kontekstu krizne evakuacije. Kroz SC2LE kao eksperimentalnu platformu ilustrira se kako bi takav kombinirani sustav mogao funkcionirati u praksi – kao rješenje primjenjivo na bilo koju krizu koja zahtijeva hitnu evakuaciju – uz kritički osvrt na ograničenja korištenog eksperimentalnog okruženja i sigurnosne implikacije automatiziranog odlučivanja u stvarnim kriznim situacijama.

2 KRIZNO UPRAVLJANJE KAO TEMELJ DONOŠENJA ODLUKA

Krizno upravljanje jedno je od ključnih područja suvremenih sigurnosnih sustava čiji je primarni cilj zaštita ljudskih života, kritične infrastrukture, okoliša i materijalnih dobara od posljedica svih prirodnih, tehnoloških i drugih izvanrednih događaja. Razvojem tehnologije i pojavom sve složenijih sigurnosnih izazova mijenja se i pristup upravljanju kriznim situacijama.

Tradicionalni pristupi bili su usmjereni na djelovanje nakon nastanka kriznog događaja te su se uglavnom temeljili na reakciji na već nastalu situaciju. S druge strane, suvremeni koncepti, uvođenjem umjetne inteligencije, velikih podatkovnih centara i tehnologije oblaka definiraju čitav niz preventivnih aktivnosti koje započinju znatno prije same krize. Kontinuiranim procesom procjene rizika, praćenjem potencijalnih prijetnji i planiranjem preventivnih mjera, jedan takav sustav ima mogućnost ne samo smanjenje posljedica kriznih situacija nego i povećanje sposobnosti njihovog pravovremenog prepoznavanja, predviđanja i, kada je to moguće, sprječavanja njihovog nastanka.

U ovom poglavlju prikazat će se temeljni koncepti sustava kriznog upravljanja, obilježja suvremenog sigurnosnog okruženja te izazovi s kojim se suočavaju donositelji odluka tijekom planiranja i upravljanja. Poseban naglasak stavljen je na razvoj kriznog upravljanja kao kontinuiranog procesa koji obuhvaća prevenciju, pripravnost, odgovor i oporavak.

2.1 Suvremeno sigurnosno okruženje

Ubrzani razvoj tehnologije, porast broja stanovnika u urbanim sredinama i klimatske promjene značajno su promijenile sliku sigurnosnih prijetnji. Izazovi s kojima se susrećemo su često povezani procesi koji istodobno mogu zahvatiti različita područja i sektore društva. Prirodne katastrofe, industrijski incidenti i sve češći kibernetički napadi zbog velike međusobne povezanosti prometnih, energetskih, informacijskih i komunikacijskih sustava često uzrokuju lančane posljedice koje dodatno otežavaju upravljanje kriznom situacijom [13].

S druge strane, razvoj informacijskih i komunikacijskih tehnologija omogućio je prikupljanje ogromne količine podataka iz različitih izvora. Geografski informacijski sustavi, satelitske snimke, bespilotne letjelice, senzorske mreže i drugi izvori danas pružaju relevantne

informacije o stanju na terenu te omogućuju kvalitetniji uvid u razvoj kriznih situacija. Međutim, sama dostupnost velike količine podataka nije prednost ako ih nije moguće pravodobno obraditi i analizirati. Upravo zbog toga javlja se potreba za razvojem inteligentnog sustava koji, primjenom metoda umjetne inteligencije, omogućuje obradu i analizu velikih količina podataka u stvarnom vremenu te pruža potporu procesu donošenja odluka [14].

2.2 Sustav kriznog upravljanja

Upravljanje kriznim situacijama zahtijeva jasno definiranu organizacijsku strukturu, raspoložive resurse te učinkovitu koordinaciju svih sudionika uključenih u proces. Jedan od ključnih preduvjeta uspješnog djelovanja sustava je kvalitetna i pravovremena razmjena informacija te učinkovita komunikacija između svih nadležnih institucija i službi [1].

U suvremenim kriznim situacijama, istodobno je potrebno uzeti u obzir više međusobno povezanih kriterija, poput raspoloživosti resursa, sigurnosti stanovništva, očuvanja kritične infrastrukture, stanja prometne infrastrukture, vremenskih uvjeta te mogućih posljedica svake odluke. Budući da kriteriji imaju različitu važnost te su često suprotstavljeni, odabir optimalnog rješenja predstavlja složen proces [3].

Suvremeni sustav kriznog upravljanja osmišljen je kako bi podržao upravo takav proces odlučivanja. Njegova osnovna zadaća je objediniti sve relevantne informacije, omogućiti njihovu obradu te donositeljima odluka pružiti cjeloviti pregled krizne situacije [15]. Osim praćenja stanja na terenu u vidu izvora i klasifikacije kriterija, sustav mora omogućiti usporedbu različitih alternativa, procjenu mogućih posljedica te vrednovanje rješenja temeljem unaprijed definiranih kriterija.

Takav pristup mijenja fokus s donošenja odluka temeljenih isključivo na iskustvu i subjektivnoj procjeni na sustavnu analizu dostupnih podataka i objektivno vrednovanje alternativa. Time se povećava kvaliteta procesa odlučivanja, olakšava upravljanje raspoloživim resursima te stvaraju preduvjeti za učinkovitiji odgovor [3].

S obzirom na dinamičnu prirodu kriznih situacija, sustav mora biti sposoban kontinuirano se prilagođavati promjenama u okruženju, neprekidno prikupljati i analizirati nove informacije, ažurirati procjenu te mijenjati plan postupanja. Na taj način sustav ne predstavlja samo alat za

odgovor na krizu, već pruža potporu u svim sferama kriznog upravljanja, od preventivnog djelovanja i pripreme do odgovora i oporavka.

2.3 Životni ciklus kriznog upravljanja

Učinkovito upravljanje ne svodi se isključivo na reakciju nakon nastanka kriznog događaja, već obuhvaća niz aktivnosti koje se provode prije, tijekom i nakon krize. Takvim pristupom omogućeno je sustavno planiranje mjera usmjerenih na smanjenje rizika, ograničiti posljedice te osigurati što brži oporavak. Iako se aktivnosti vremenski mogu preklapati, životni ciklus se često promatra kroz četiri međusobno povezane, ali distinktne faze: ublažavanje rizika, pripremu, odgovor i oporavak [1], [16].

Fazom ublažavanja rizika (eng. *mitigation*) nastoji se smanjiti vjerojatnost nastanka kriznih događaja i ublažiti njihove moguće posljedice. U ovoj fazi provodi se procjena rizika, analiziraju se potencijalne prijetnje te definiraju strategije, procedure i preventivne mjere kojima se nastoji povećati otpornost sustava. Između ostalog, nastoji se i naučiti iz prethodno napravljenih grešaka iz svih faza ciklusa prethodnog kriznog događaja.

U fazi pripreme (eng. *preparedness*), razvijaju se operativni planovi, nabavljaju i organiziraju potrebni resursi te uspostavljaju postupci koji omogućuju pravodobno djelovanje u slučaju krizne situacije. U ovoj fazi posebna se pozornost posvećuje koordinaciji sudionika, razmjeni informacija, edukaciji i provedbi različitih vježbi.

Pojavom krize započinje faza odgovora (eng. *response*). Njezina osnovna zadaća je zaštita ljudskih života, smanjenje materijalne štete te osiguravanje kontinuiteta ključnih funkcija sustava. Okolnosti se vrlo brzo mijenjaju stoga je potrebno donositi veliku količinu odluka u jako kratkom vremenu uz razmatranje velikog broja informacija i ograničenih raspoloživih sredstava. Upravo zato je koordinacija svih uključenih sudionika jedan od najvažnijih čimbenika uspješnog odgovora.

Posljednju fazu čini oporavak (eng. *recovery*), čiji je cilj obnoviti uništeno, i u što kraćem roku omogućiti povratak u redovito funkcioniranje. Osim obnove i normalizacije društva, u ovoj se fazi analiziraju provedene mjere te nastoje utvrditi nedostatci u sustavu. Dobivena saznanja će se koristiti za daljnje unaprjeđenje planova i postupaka.

Donošenje odluka prisutno je u svim fazama životnog ciklusa kriznog upravljanja. Od procjene rizika i planiranja preventivnih mjera, preko odabira aktivnosti tijekom odgovora pa sve do određivanja prioriteta za vrijeme oporavka, kvaliteta donesenih odluka izravno utječe na učinkovitost sustava. Zbog toga suvremeni sustavi sve češće primjenjuju metode koje omogućuju sustavnu analizu dostupnih informacija i vrednovanje raspoloživih alternativa prema unaprijed definiranim kriterijima. Takve metode nazivamo metodama višekriterijskog odlučivanja te će biti detaljno prikazane u sljedećem poglavlju.

3 METODE VIŠEKRITERIJSKOG ODLUČIVANJA

Odlučivanje često uključuje odabir između više mogućih alternativa koje se razlikuju prema većem broju kriterija. Kod jednostavnijih problema odluka je često temeljena na jedno dominantnom kriteriju, dok se u složenijim sustavima, poput kriznog upravljanja, razmatra ogroman niz različitih kriterija koji nerijetko imaju različitu važnost te su često suprotstavljeni [3].

Da bismo riješili takve probleme, razvijene su metode višekriterijskog odlučivanja (eng. *Multi-Criteria Decision Making – MCDM*). Osnovna im je zadaća vrednovanje i rangiranje alternativa uz razmatranje većeg broja kriterija, pri čemu se i svakom kriteriju može dodijeliti odgovarajuća razina važnosti [4].

Područje kriznog upravljanja upravo iziskuje postojanje ovih metoda, gdje je potreba za analizom velikog broja mogućih scenarija te brzo donošenje odluka s eliminacijom faktora subjektivnosti od iznimne važnosti. U nastavku poglavlja bit će prikazana osnovna načela višekriterijskog odlučivanja, nakon čega će detaljno biti obrađene metode poput AHP, TOPSIS i VIKOR, koje se ubrajaju među najčešće korištene metode u području višekriterijskog odlučivanja.

3.1 Osnovni koncepti višekriterijskog odlučivanja

Neovisno o matematičkom modulu na kojem se temelje, metode višekriterijskog odlučivanja, polaze od koncepta prema kojem je problem odlučivanja potrebno unaprijed strukturirati [3].

Prvi korak u oblikovanju modela predstavlja definiranje cilja. Cilj određuje što model želi postići te predstavlja svojevrsno polazište za određivanje ostalih elemenata. Definiranjem cilja, moguće je definirati alternative, odnosno skup rješenja koji se najviše podudara sa prvobitnim ciljem. U području kriznog upravljanja to mogu biti evakuacijske rute, raspored interventnih timova ili drugi operativni scenariji.

Nakon određivanja alternativa potrebno je definirati kriterije prema kojim će biti vrednovane. Kriteriji predstavljaju sva ona svojstva koja opisuju kvalitetu pojedine alternative te omogućuju njihovu usporedbu. Izbor kriterija je na dizajnerima sustava, ovisi o prirodi problema s kojim

se suočava. Uobičajeno je za sustave kriznog upravljanja razmatrati kriterije poput sigurnosti stanovništva, vremena evakuacije, prohodnosti prometa ili dostupnosti resursa.

Budući da kriteriji nemaju jednak utjecaj na konačan ishod, svakome se dodjeljuje težina kojom mu se određuje relativna važnost u odnosu na ostale kriterije. Ovo se smatra jednim od najvažnijih koraka u procesu višekriterijskog odlučivanja te upravo oni predstavljaju jedan od ključnih čimbenika koji utječu na konačno rangiranje alternativa [5].

Sve prikupljene informacije organiziraju se u obliku matrice odlučivanja u kojoj redci predstavljaju alternative, a stupci kriterije prema kojim se one vrednuju. Takva matrica čini osnovu većine metoda te omogućuje njihovu daljnju matematičku obradu. Sve metode (AHP, VIKOR i TOPSIS) iako koriste različite postupke vrednovanja i rangiranja alternativa, uglavnom kao polazište koriste upravo ovako definirani model problema [4]. U nastavku će biti prikazane te tri metode koje se ubrajaju među najčešće primjenjive u području kriznog upravljanja.

3.2 AHP

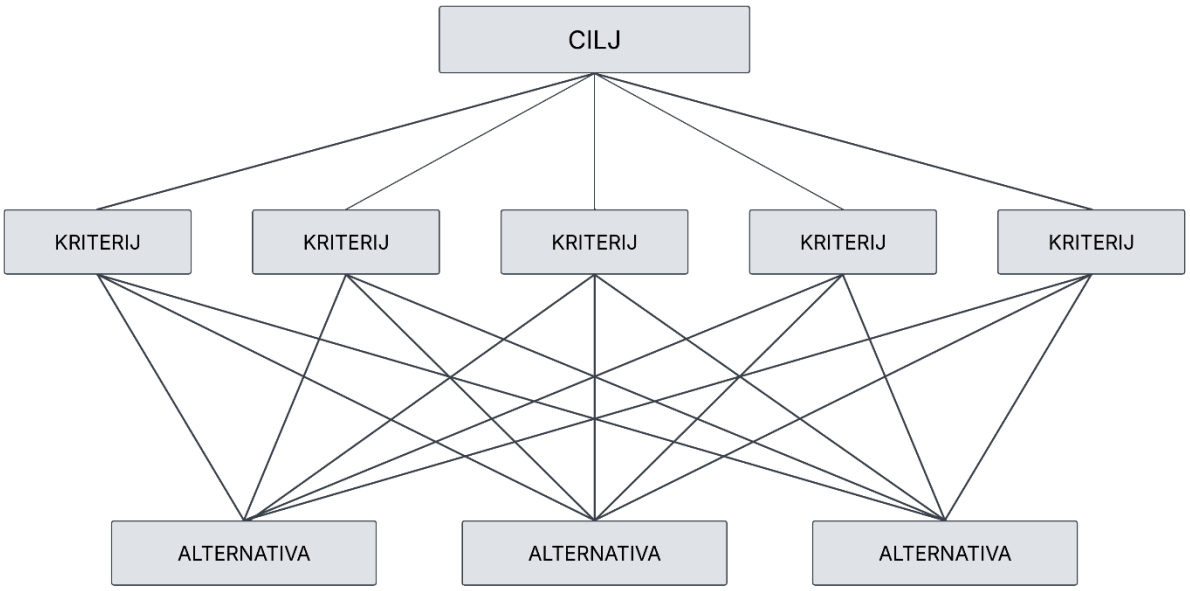
Jedna od najpoznatijih i najčešće primjenjivih metoda višekriterijskog odlučivanja je analitički hijerarhijski proces (eng. *Analytic Hierarchy Process)* [5]. Razvio ju je američki matematičar Thomas L. Saaty 1980. godine s ciljem pružanja sustavnog pristupa rješavanju složenih problema odlučivanja u kojima je potrebno istovremeno uzeti u obzir velik broj međusobno suprotstavljenih kriterija. Zbog svoje praktičnosti, AHP se brzo proširio izvan čiste matematike. Danas se redovito koristi u prometu, zdravstvu, energetici, zaštiti okoliša, upravljanju projektima te sustavima kriznog upravljanja, kao alat za određivanje prioriteta i potpora pri donošenju odluka.

Za razliku od većine drugih metoda koje izravno vrednuju alternative te pridruže apsolutne ocjene svakoj, AHP se temelji na međusobno parnim usporedbama elemenata iste hijerarhije. Donositelj odluke pritom ne procjenjuje apsolutnu vrijednost pojedinog kriterija ili alternative, već relativnu važnost u odnosu na drugi element [5]. Time se pojednostavljuje proces odlučivanja te olakšava određivanje njihove međusobne važnosti, posebno kod složenih problema koji uključuju velik broj kriterija i alternativa.

3.2.1 Hijerarhijska struktura AHP metode

Među najvažnijim obilježjima AHP metode nalazi se hijerarhijska struktura. Umjesto promatranja problema kao jedinstvene cjeline, metoda ga razlaže na više međusobno povezanih razina. Razložene manje i preglednije cjeline moguće je zasebno analizirati zasebno, a olakšavaju i razumijevanje između cilja, kriterija, podkriterija i mogućih alternativa [5].

Na samome vrhu hijerarhije nalazi se cilj odlučivanja, točnije željeni ishod procesa. Razinu ispod čine kriteriji, a ukoliko je potrebno dodaje se i razina podkriterija. Na posljednjoj razini nalaze se alternative među kojima se provodi konačan odabir [5]. Ovakva struktura jasno definira odnose između svih elemenata modela i kasnije olakšava parne usporedbe.



Slika 3-1 Opći primjer hijerarhijske strukture AHP metode

Primjerice, kod planiranja evakuacije tijekom požara cilj može biti odabir optimalne evakuacijske rute. Kriteriji mogu uključivati očekivano vrijeme evakuacije, sigurnost i prohodnost prolaza, izloženost dimu ili dostupnost interventnih službi. Prema potrebi moguće je svaki od navedenih kriterija dodatno razložiti na podkriterije, čime se omogućuje detaljnije vrednovanje pojedinih aspekata problema. Nadalje, alternative predstavljaju različite moguće evakuacijske rute koje sustav uspoređuje i rangira. Na taj se način problem oblikuje u hijerarhijsku strukturu pogodnu za AHP metode.

Kao temelj uspješne primjene AHP metode je pravilno definiranje hijerarhijske strukture. Ako jedna od razina nije jasno određena, dobiveni rezultat neće vjerno predstaviti stvarni problem odlučivanja, bez obzira na točnost samog matematičkog postupka.

3.2.2 Parne usporedbe i Saatyjeva skala

Poslije definiranja hijerarhijske strukture potrebno je odrediti relativnu važnost svih kriterija i alternativa. U AHP metodi to se postiže parnim usporedbama, pri čemu se elementi iste razine uspoređuju dva po dva. Donositelju odluke ovakav pristup omogućuje da se usredotoči na usporedbu samo dva elementa u zadanom trenutku [5].

Svakom usporedbom cilj je procijeniti koji je od promatranih elemenata važniji te u kojoj mjeri. Thomas Saaty je za izražavanje relativne važnosti predložio numeričku skalu od 1 do 9, poznatu kao Saatyeva skala [17]. Vrijednost 1 predstavlja jednaku važnost dvaju elemenata, dok vrijednost 9 predstavlja dominantnost jednog elementa u odnosu na drugi. Vrijednosti 2, 4 ,6 i 8 koriste se kao međuvrijednosti kada procjenu nije moguće jednoznačno izraziti osnovnim vrijednostima [5].

Tablica 3-1 Saatyjeva skala

Ocjena prioriteta	Opisna ocjena prioriteta
1	Jednaki
2	Jednaki do umjereni
3	Umjereni
4	Umjereni do jaki
5	Jaki
6	Jaki do vrlo jaki
7	Vrlo jaki
8	Vrlo jaki do aspolutni
9	Apsolutni

U kontekstu hitne evakuacije tijekom požara, donositelj odluke može, primjerice, uspoređivati evakuacijske rute s vremenom potrebnim za evakuaciju. Ukoliko je procjena da je sigurnost znatno važnija od brzine evakuacije, toj usporedbi može se dodijeliti vrijednost 5, čime se izražava znatna prednost sigurnosti u odnosu na vrijeme evakuacije. Na isti način provodi se usporedba svih postojećih kriterija, a zatim i svih alternativa prema svakom od pojedinih kriterija.

Rezultati svih parnih usporedbi organiziraju se u matricu koja predstavlja osnovu za izračun težina kriterija i alternativa. Iz te matrice u sljedećim koracima proizlaze prioriteti koji određuju konačno rangiranje svih razmatranih ishoda.

3.2.3 Matematički model AHP metode

Provedbom parnih usporedbi procjene je potrebno pretvoriti u numeričke težine koje će predstavljati relativnu težinu svakog kriterija. U AHP metodi se to radi izgradnjom matrice parnih usporedbi te izračunom prioriteta korištenjem postupka temeljenog na svojstvima

vlastitih vrijednosti i vlastitih vektora matrice. Matematički model koji slijedi u nastavku poglavlja preuzet je i temelji se na izvornom prikazu AHP metode [5].

$$A = \begin{bmatrix} 1 & a_{12} & \dots & a_{1n} \\ 1/a_{12} & 1 & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 1/a_{1n} & 1/a_{2n} & \dots & 1 \end{bmatrix}$$

Slika 3-2 Matrica parnih usporedbu

Matrica parnih usporedbi (slika 3-2) kvadratna je matrica reda $n \times n$, gdje n predstavlja broj kriterija ili alternativa koje se uspoređuju. Svaki element matice a_{ij} označava relativnu važnost elementa *i* u odnosu na element *j*. Važnosti se određuju Saatyjevom skalom, pri čemu je: $a_{ij} = \frac{1}{a_{ji}}$, što znači ako element *i* vrijedi *k* puta više od elementa $j(a_{ij} = k)$, tada element *j* vrijedi *1/k* u odnosu na element $i(a_{ji} = 1/k)$ odnosno matrica je recipročna. Osim toga, svi elementi glavne dijagonale imaju vrijednost 1 jer se svaki kriterij uspoređuje sa samim sobom.

Kako bi pobliže ilustrirali primjenu matrice parnih usporedbi razmotrit će se primitivni primjer odabira optimalne evakuacijske rute tijekom požara. Pretpostavlja se da je alternativa vrednovana prema trima kriterijima: sigurnost, vrijeme evakuacije i prohodnost puta. Donositelj odluke procjenjuje da je sigurnost rute znatno važnija od vremena potrebnog za evakuaciju (vrijednost 5), nadalje sigurnost puta je umjereno važnija od prohodnosti puta (vrijednost 3), dok je prohodnost nešto važnija od vremena evakuacije (vrijednost 2). Kad bi te brojeve ubacili u matricu gdje je prvi redak i prvi stupac označavaju sigurnost, drugi vrijeme, a treći prohodnost dobili bi matricu na slici 3-3.

$$\begin{bmatrix} 1 & 5 & 3 \\ 1/5 & 1 & 1/2 \\ 1/3 & 2 & 1 \end{bmatrix}$$

Slika 3-3 Matrica primitivnog primjera odabira optimalne evakuacijske rute tijekom požara

Promatrajući matricu parnih usporedbi može se izdvojiti kriterij sigurnosti kao primjer. Iščitamo da je sigurnost stoga 5 puta važnija od vremena, a 3 puta važnija od prohodnosti. Odnosi su tako definirani među svim kriterijima.

Na temelju formirane matrice u daljnjem postupku moguće je odrediti relativnu važnost svakog kriterija. U AHP metodi ta se važnost izražava kroz težinske koeficijente, koji predstavljaju doprinos pojedinog kriterija konačnoj odluci. Veća težina kriterija znači njegov veći utjecaj na odabir najbolje alternative [5].

Izračun se provodi normalizacijom matrice. Prvim korakom izračunava se zbroj svih elemenata unutar svakog stupca matrice. U primjeru sa slike 3-3, prvi stupac približno iznosi 1,533, drugi 8, a treći 4,5. Nakon toga svaki element matrice dijeli se zbrojem pripadajućeg stupca, čime se dobiva normalizirana matrica (slika 3-4) čiji elementi poprimaju vrijednosti između 0 i 1.

$$\begin{bmatrix} 0{,}652 & 0{,}625 & 0{,}667 \\ 0{,}130 & 0{,}125 & 0{,}111 \\ 0{,}217 & 0{,}250 & 0{,}222 \end{bmatrix}$$

Slika 3-4 Normalizirana matrica

Na kraju se izračunava aritmetička sredina vrijednosti svakog retka normalizirane matrice. Tim postupkom dobiva se vektor prioriteta (slika 3-5) odnosno težina pojedinih kriterija [5].

$$\begin{bmatrix} 0{,}648 \\ 0{,}122 \\ 0{,}230 \end{bmatrix}$$

Slika 3-5 Vektor prioriteta

Iz dobivenog vektora prioriteta vidljivo je da najveću težinu ima sigurnost (0,648), zatim prohodnost (0,230), dok vrijeme evakuacije nosi najmanju težinu (0,122). Dobivene težine omogućuju rangiranje kriterija prema njihovoj važnosti te predstavljaju osnovu za vrednovanje alternativa.

3.2.4 Konzistentnost usporedbi

Budući da su parne usporedbe AHP metode temeljene na subjektivnoj procjeni donositelja odluke, postoji mogućnost pojave međusobno proturječnih, nelogičnih procjena kada govorimo o velikom broju kriterija. Primjerice, ako je sigurnost važnija od vremena evakuacije, a vrijeme važnije od prohodnosti, očekivano bi bilo da je i sigurnost važnija od prohodnosti. Ukoliko takav odnos nije zadovoljen, tada je došlo do nekonzistentnosti [5].

Provjera konzistentnosti provodi se izračunom indeksa konzistentnosti (eng. *Consistency Indeks – CI*) te omjera konzistentnosti (eng. *Consistency Ratio – CR*) [5].

Indeks konzistentnosti određen je izrazom [5]:

$$CI = \frac{\lambda_{max} - n}{n - 1} \tag{3-1}$$

gdje je:

- λ_{max} – najveća vlastita vrijednost matrice parnih usporedbi
- n – broj kriterija

Vrijednost indeksa konzistentnosti sama po sebi nije dovoljna za procjenu kvalitete usporedbi stoga je potrebno izračunati omjer konzistentnosti [5]:

$$CR = \frac{CI}{RI} \tag{3-2}$$

pri čemu je:

- *RI* (eng. *Random Index*) - slučajni indeks koji ovisi o dimenziji matrice

Vrijednost slučajnog indeksa određuje se prema unaprijed definiranim vrijednostima (tablica 3-2). Za matrice reda 3, kao što je slučaj u primjeru, vrijednost slučajnog indeksa *RI* = 0,58 [5].

Tablica 3-2 Unaprijed definirane vrijednosti slučajnog indeksa RI [5]

n	**1**	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**	**10**
RI	0,00	0,00	0,58	0,9	1,12	1,24	1,32	1,41	1,45	1,49

U praksi vrijednosti *CR* < 0,10 ukazuju na to da su procjene međusobno dovoljno dosljedne te se dobivene težine mogu koristiti u daljnjem postupku odlučivanja. Ako je omjer veći od 0,10 potrebno je ispraviti nelogičnosti [5].

3.2.5 Primjena AHP metode u sustavima kriznog upravljanja te njezine prednosti i ograničenja

Analitički hijerarhijski proces (AHP) danas je jedna od najčešće korištenih metoda višekriterijskog odlučivanja u područjima gdje je velik broj međusobno povezanih kriterija. Zbog mogućnosti određivanja relativne važnosti kriterija, provjere konzistentnosti i strukturiranja složenih problema, AHP metoda pronašla je široku primjenu u prometu, upravljanju projektima, zdravstvu, energetici te sustavima kriznog upravljanja.

Tijekom planiranja hitne evakuacije, npr. uslijed požara, potrebno je istodobno razmotriti sigurnost, vrijeme, prohodnost, raspoloživost interventnih službi i brojnih drugih čimbenika. Budući da nemaju jednaku važnost, AHP kriterije objektivno vrednuje kroz sustav parnih usporedbi.

U predloženom sustavu za potporu odlučivanja u hitnoj evakuaciji, koji kombinira MCDM metode s algoritmima podržanog učenja, AHP metoda predstavlja početnu fazu procesa odlučivanja. Prema prikupljenim podacima i stručnim provjerama određuju se težine svih relevantnih kriterija, koji zatim služe kao ulazni parametri drugim metodama. Na taj način AHP ne donosi konačnu odluku, već definira važnost pojedinih kriterija koji će kasnije biti korišteni u postupku rangiranja alternativa.

S druge strane, metoda ima i određena ograničenja. S povećanjem broja kriterija i alternativa raste broj potrebnih parnih usporedbi, čime postupak postaje vremenski zahtjevniji i povećava mogućnost pogrešaka. Osim toga, AHP pretpostavlja da su težine kriterija određene u jednom trenutku te ih se tijekom izračuna ne prilagođava promjenama u okruženju. Zbog toga metoda nije dovoljna za donošenje odluka u izrazito dinamičkim kriznim situacijama.

Iz navedenih razloga AHP se u suvremenim sustavima potpore rijetko koristi samostalno. Najveća vrijednost metode ostvaruje se kombinacijom s drugim metodama višekriterijskog odlučivanja i algoritmima umjetne inteligencije, pri čemu AHP odredi relativnu važnost kriterija, dok druge metode koriste dobivene težine u daljnjim procesima. Upravo će takav pristup biti razmatran u nastavku rada kroz metode TOPSIS i VIKOR te njihovu integraciju u jedinstveni sustav za potporu odlučivanja tijekom hitne evakuacije.

3.3 VIKOR

Visoko-kriterijska optimizacija i kompromisno rješenje, poznatije pod nazivom VIKOR (VIšekriterijumsko KOmpromisno Rangiranje) [7], jedna je od najpoznatijih metoda višekriterijskog odlučivanja namijenjena rješavanju problema u kojima nije moguće pronaći alternativu koja istodobno postiže najbolji rezultat prema svim promatranim kriterijima. VIKOR za razliku od ostalih metoda koje pokušavaju odrediti jedinstveno optimalno rješenje, polazi od pretpostavke da je u stvarnim problemima odlučivanja, poput kriznog upravljanja, potrebno pronaći kompromisno rješenje koje na najbolji mogući način u ravnotežu stavlja međusobno suprotstavljene zahtjeve [7].

Metodu je razvio Serafim Opricović, dok je daljnju razradu i primjenu ostvario u suradnji s Gwo-Hshiung Tzengom. Od predstavljanja metode pa do danas, VIKOR se primjenjuje u brojnim područjima poput prometnog planiranja, građevine, energetike, medicine te sustava kriznog upravljanja [7].

VIKOR posebno dolazi do izražaja u kriznim situacijama, gdje je donošenje odluke gotovo uvijek popraćeno nizom kompromisa između više ciljeva. Tijekom hitne evakuacije, primjerice uslijed požara, najkraća ruta ne mora biti ujedno i najsigurnija, dok najsigurnija ruta često zahtjeva dulje vrijeme evakuacije ili veći angažman nadležnih službi i upotrebu većeg broja raspoloživih resursa, kao što smo to prethodno zaključili AHP metodom. U takvim okolnostima cilj nije pronaći jedinstveno savršeno rješenje, već alternativu koja predstavlja najprihvatljiviji kompromis između sigurnosti, vremena evakuacije, prohodnosti prometnica i puteva, ili ostalih kriterija koji utječu na donošenje odluke.

U sustavu za potporu odlučivanju VIKOR se koristi za rangiranje mogućih evakuacijskih ruta na temelju unaprijed određenih težina. Time je omogućeno donošenje odluke koja nije optimalna samo prema jednom kriteriju, nego predstavlja uravnoteženo rješenje koje u najvećoj mogućoj mjeri zadovoljava sve zahtjeve promatranog problema. U nastavku poglavlja bit će prikazana temeljna načela VIKOR metode, matematički model te primjena u sustavu za potporu odlučivanja tijekom hitne evakuacije.

3.3.1 Načelo rada VIKOR metode

Proces odlučivanja primjenom VIKOR metode počinje definiranjem skupa alternativa i kriterija prema kojim će se provoditi njihovo vrednovanje. Razlika u odnosu na AHP metodu je u tome da VIKOR pretpostavlja da su kriteriji, njihove težine i promatrane alternative unaprijed definirane te ih koristi kao ulazne podatke u postupku kompromisnog rangiranja. S druge strane AHP se primarno koristi za određivanje važnosti kriterija [7].

Jedno od temeljnih načela rada VIKOR metode jest usporedba svake alternative s idealnim i anti-idealnim rješenjem. Idealno rješenje predstavlja hipotetsku alternativu koja je za svaki promatrani kriteriji ostvarila najbolju moguću vrijednost, dok anti-idealno rješenje predstavlja alternativu s najnepovoljnijim vrijednostima svih kriterija. Naravno, te alternative često ne postoje, već samo služe kao referente točke za objektivnu procjenu svih razmatranih rješenja [7].

VIKOR također ne rangira alternative isključivo prema njihovoj ukupnoj uspješnosti, već istodobno analizira dva različita aspekta kvalitete alternative. Prvi predstavlja njezino ukupno odstupanje od idealnog rješenja, dok drugi opisuje najveće pojedinačno odstupanje prema bilo kojem kriteriju. Takvim pristupom metoda nastoji izbjeći trenutak kada alternativa ostvaruje vrlo dobre rezultate prema većini kriterija, ali pritom značajno odstupa prema kriteriju koji može biti presudan u odlučivanju kada je u pitanju konačan ishod. Kombiniranjem pokazatelja određuje se kompromisno rješenje koje predstavlja najuravnoteženiju alternativu između svih razmatranih kriterija [7].

Ono što VIKOR metodu čini zanimljivom jest mogućnost prilagodbe različitim strategijama odlučivanja. Ovisno o prirodi problema s kojim smo suočeni, moguće je dati veću važnost ukupnoj koristi svih kriterija ili veću važnost ograničavanju najveće pojedinačnog odstupanja od idealnog rješenja. Metoda se tako može prilagoditi različitim zahtjevima sustava i preferencama donositelja odluke [7].

U sustavima kriznog upravljanja, u uvjetima ograničenog vremena, nepotpunih informacija i velikog broja međusobno povezanih kriterija, takav pristup ima posebno značenje. Primjerice, tijekom hitne evakuacije jedna ruta može omogućiti najkraće vrijeme izlaska, ali pritom dovesti ljude u veliku opasnost, dok druga može biti sigurna, ali zahtijeva dulje vrijeme što može

potrošiti više resursa od očekivanog te u konačnici ljude svejedno dovesti u opasnost. U takvoj situaciji nije dovoljno promatrati jedan od kriterija, već prema VIKOR metodi pronaći alternativu koja ostvaruje najbolji mogući kompromis između sigurnosti, vremena, prohodnosti, dostupnosti resursa i ostalih faktora.

Zbog navedenih karakteristika VIKOR je prikladan alat za implementaciju u sustav potpore za odlučivanje. Matematički model kojim se provodi navedeni postupak prikazan je u nastavku poglavlja.

3.3.2 Matematički model VIKOR metode

Temeljena na sustavnom vrednovanju unaprijed definiranih alternativa prema skupu odabranih kriterija, VIKOR metoda postupak započinje formiranjem matrice odlučivanja (slika 3-6). U matrici svaki redak odgovara jednoj alternativi, dok svaki stupac predstavlja jedan od kriterija prema kojem se provodi vrednovanje. Elementi matrice predstavljaju vrijednost pojedinog kriterija za svaku promatranu alternativu [7].

Iako stvarni sustavi kriznog upravljanja uključuju znatno veći broj kriterija, u ovom poglavlju koristi se pojednostavljeni primjer kako bi se jasnije prikazao postupak, a radi preglednijeg prikaza matematičkog postupka korišten je isti skup kriterija kao i u primjeru AHP metode.

$$F = \begin{bmatrix} f_{11} & f_{12} & \cdots & f_{1m} \\ f_{21} & f_{22} & \cdots & f_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ f_{n1} & f_{n2} & \cdots & f_{nm} \end{bmatrix}$$

Slika 3-6 Matrica odlučivanja VIKOR metode

Objašnjenje elemenata matrice odlučivanja prikazane na slici 3-6:

- n – broj kriterija
- m – broj alternativa
- f_{ij} – vrijednost i-tog kriterija za j-tu alternativu

Primjer matrice odlučivanja korištene u ovom radu prikazan je u tablici 3-3.

Napomena: Prikazane vrijednosti predstavljaju hipotetske ekspertne ocjene na skali od 1 do 9 te služe isključivo za ilustraciju matematičkog postupka VIKOR metode.

Tablica 3-3 Primjer matrice odlučivanja za VIKOR metodu

Kriterij / Alternativa	Ruta A	Ruta B	Ruta C
Sigurnost	9	7	8
Vrijeme evakuacije	5	9	6
Prohodnost	6	7	9

Ruta A ostvaruje najveću razinu sigurnosti, ali zahtijeva dulje vrijeme evakuacije zbog obilaznog pravca. Ruta B omogućuje najbržu evakuaciju, no prolazi područjem povećanog rizika. Ruta C odlikuje se najboljom prohodnošću prometnica, ali ne postiže najbolje rezultate prema ostalim kriterijima.

Nakon formiranja matrice potrebno je odrediti idealnu i anti-idealnu vrijednost za svaki promatrani kriterij. Idealna vrijednost predstavlja najbolji ostvareni rezultat pojedinog kriterija

među svim razmatranim alternativama, dok anti-idealna vrijednost predstavlja najnepovoljniji rezultat.

Budući da su u ovom primjeru svi kriteriji prikazani kao ekspertne ocjene, veća vrijednost označava povoljnije zadovoljavanje pojedinog kriterija. Zbog toga je idealna vrijednost ona najveća, dok anti-idealna odgovara najmanjoj vrijednosti. U stvarnim sustavima pojedini kriteriji, poput vremena evakuacije izraženog u minutama ili ukupnog troška evakuacije, predstavljaju kriterije koje je potrebno minimizirati, pri čemu se postupak određivanja rješenja treba prilagoditi prirodi promatranog kriterija [7].

Za kriterije koje je potrebno maksimizirati idealna i anti-idealna vrijednost određuju se izrazima [7]:

$$f_i^* = \max_j(f_{ij}) \tag{3-3}$$

$$f_i^- = \min_j(f_{ij}) \tag{3-4}$$

gdje je:

- f_i^* – idealna vrijednost *i*-tog kriterija
- f_i^- – anti-idealna vrijednost *i*-tog kriterija
- f_{ij} – vrijednost *i*-tog kriterija za *j*-tu alternativu
- $i = 1, 2, \dots, n$.
- $j = 1, 2, \dots, m$.

Primjenom izraza na matricu odlučivanja iz tablice 3-3 dobiju se idealne i anti-idealne vrijednosti prikazane u tablici 3-4.

Tablica 3-4 Idealne i anti-idealne vrijednosti kriterija

Kriterij	Idealna vrijednost f_i^*	Anti-idealna vrijednost f_i^-
Sigurnost	9	7
Vrijeme evakuacije	9	5
Prohodnost	9	6

3.3.3 Normalizacija kriterijskih vrijednosti

Određivanjem idealnih i anti-idealnih vrijednosti provodi se normalizacija kriterijskih vrijednosti. Pojedini kriteriji mogu biti izraženi različitim mjernim jedinicama i imati različite raspone vrijednosti, stoga njihova izravna usporedba nije moguća. Cilj normalizacije je sve kriterije svesti na zajedničku skalu kako bi svaki mogao ravnopravno sudjelovati u daljnjim izračunima [7].

Za kriterije koje je potrebno maksimizirati normalizirano odstupanje određuje se izrazom [7]:

$$d_{ij} = \frac{f_i^* - f_{ij}}{f_i^* - f_i^-} \tag{3-5}$$

gdje je:

- d_{ij} – normalizirano odstupanje *i*-tog kriterija za *j*-tu alternativu
- f_i^* – idealna vrijednost *i*-tog kriterija
- f_i^- – anti-idealna vrijednost *i*-tog kriterija
- f_{ij} – vrijednost *i*-tog kriterija za *j*-tu alternativu

Vrijednost d_{ij} nalazi se u intervalu $[0, 1]$. Vrijednost 0 označava da alternativa postiže idealnu vrijednost promatranog kriterija, dok vrijednost 1 predstavlja najveće moguće odstupanje od idealnog rješenja. Relativnu udaljenost od idealnog rješenja predstavljaju ostale vrijednosti.

U nastavku je prikazan primjer izračuna normalizirane vrijednosti za kriterij sigurnosti i alternativu Ruta A:

$$d_{11} = \frac{9 - 9}{9 - 7} = 0$$

Primjenom istog postupka na sve ostale elemente matrice odlučivanja dobiva se normalizirana matrica prikazana u tablici 3-5.

Tablica 3-5 Normalizirana matrica odlučivanja

Kriterij / Alternativa	Ruta A	Ruta B	Ruta C
Sigurnost	0,000	1,000	0,500
Vrijeme evakuacije	1,000	0,000	0,750
Prohodnost	1,000	0,667	0,000

Dobivena normalizirana matrica predstavlja osnovu za izračun pokazatelja S i R, kojima se određuje ukupna korisnost i maksimalno pojedinačno odstupanje svake alternative od idealnog rješenja. Temeljem tih pokazatelj izračunava se kompromisni indeks Q, prema kojem se provodi konačno rangiranje alternativa.

3.3.4 Izračun pokazatelja S, R i Q

Provedenom normalizacijom kriterijskih vrijednosti krećemo u izračun pokazatelja S i R, koji su osnova za određivanje kompromisnog indeksa Q. Pokazatelj S opisuje ukupnu udaljenost pojedine alternative od idealnog rješenja uzimajući u obzir sve kriterije, dok pokazatelj R predstavlja najveće pojedinačno odstupanje alternative prema bilo kojem kriteriju. Izračunom kompromisnog indeksa Q možemo provesti konačno rangiranje svih razmatranih alternativa [7].

Pokazatelj S određuje se izrazom [7]:

$$S_j = \sum_{i=1}^{n} w_i \frac{f_i^* - f_{ij}}{f_i^* - f_i^-} \tag{3-6}$$

gdje je:

- S_j – ukupna udaljenost *j*-te alternative od idealnog rješenja
- w_i – težina *i*-tog kriterija
- d_{ij} – normalizirano odstupanje *i*-tog kriterija za *j*-tu alternativu

Budući da je normalizirano odstupanje već izračunato u prethodnom koraku, izraz se može zapisati i jednostavniji oblikom [7]:

$$S_j = \sum_{i=1}^{n} w_i d_{ij} \tag{3-7}$$

Nakon toga određuje se pokazatelj R [7]:

$$R_j = \max_i (w_i d_{ij}) \tag{3-8}$$

Pokazatelj R predstavlja najveće ponderirano odstupanje pojedine alternative od idealnog rješenja, odnosno kriterij koji za promatranu alternativu predstavlja najveći nedostatak.

Temeljem vrijednosti S i R određuje se kompromisni indeks Q izrazom [7]:

$$Q_j = v\frac{S_j - S^*}{S^- - S^*} + (1 - v)\frac{R_j - R^*}{R^- - R^*} \tag{3-9}$$

gdje je:

- Q_j – kompromisni indeks *j*-te alternative
- S^* – najmanja vrijednost pokazatelja S
- S^- – najveća vrijednost pokazatelja S
- R^* – najmanja vrijednost pokazatelja R
- R^- – najveća vrijednost pokazatelja R
- v – težinski parametar koji određuje odnos između strategije maksimalne grupne koristi i strategije minimalnog pojedinačnog odstupanja. U većini primjena koristi se vrijednost $v = 0{,}5$, čime se daje jednaka važnost objema strategijama [7]

Alternative se zatim rangiraju prema rastućim vrijednostima pokazatelja Q. Alternativa koja ima najmanju vrijednost pokazatelja Q smatra se kompromisnim rješenjem jer predstavlja najbolju ravnotežu ukupne koristi i najvećeg pojedinačnog odstupanja od idealnog rješenja.

3.3.5 Primjena VIKOR metode u kriznom upravljanju

Zbog svoje sposobnosti kompromisnog rangiranja VIKOR metoda je posebno pogodna za primjene u sustavima kriznog upravljanja. Potrebno je donositi veliki broj odluka simultano, dok kriteriji često znaju biti suprotstavljeni, a vrijeme za odluku ograničeno [7].

U području hitne evakuacije metoda se koristi za rangiranje mogućih evakuacijskih ruta uzimajući u obzir kriterije poput sigurnosti, vremena evakuacije, prohodnosti prometnica, dostupnosti interventnih službi i razine rizika na pojedinim prometnim pravcima. Umjesto odabira rute koja je najbolja prema samo jednom značajnom kriteriju, VIKOR metoda omogućuje pronalazak alternative koja predstavlja najbolji kompromis između svih promatranih zahtjeva kao što smo to vidjeli u pojednostavljenom primjeru prethodnog poglavlja.

Osim planiranja evakuacije, metoda se primjenjuje pri određivanju prioriteta raspodjele često ograničenih resursa tijekom kriznih situacija, kao što je to raspoređivanje vatrogasnih i medicinskih timova, odabir lokacija privremenih skloništa te određivanje prioriteta sanacije infrastrukture nakon prirodnih ili tehnoloških katastrofa. Tako je omogućeno sustavno i objektivno donošenje odluka u situacijama u kojima ne postoji jasno idealno rješenje.

U suvremenim sustavima potpore VIKOR se često kombinira s geografskim informacijskih sustavima (GIS) i drugim računalnim alatima za analizu prostornih i operativnih podataka. Takva integracija omogućuje vrednovanje alternativa i pruža pouzdaniju osnovu za odabir optimalne strategije djelovanja u različitim kriznim scenarijima [7].

3.3.6 Prednosti i ograničenja VIKOR metode

U problemima u kojima je potrebno pronaći kompromisno rješenje više međusobno suprotstavljenih kriterija VIKOR metoda dobiva na važnosti. Jeda od njezinih najvećih prednosti jest mogućnost istodobnog razmatranja ukupne korisnosti pojedine alternative i njezina najvećeg pojedinačnog odstupanja od idealnog rješenja. Metoda tako omogućuje donošenje relativno uravnoteženih odluka i smanjuje mogućnost odabira rješenja koje ostvaruje izrazito nepovoljan rezultat prema nekom od važnih kriterija [7].

Prednost VIKOR metode, što nije isključivo vezano samo za nju, jest mogućnost kombiniranja s drugim metodama višekriterijskog odlučivanja. U praksi se često koristi zajedno s metodama za određivanje težine kriterija, poput AHP metode, čime je moguće postići objektivnije vrednovanje alternativa i povećati pouzdanost procesa odlučivanja. Također jedna od važnih prednosti metode je mogućnost prilagodbe parametra v, kojim donositelj odluke može odrediti odnos između maksimalne grupne koristi i minimalnog pojedinačnog rješenja [7].

Jednostavnost matematičkog postupka te jasan sustav rangiranja alternativa predstavljaju još jednu od prednosti metode. Osim određivanja konačnog poretka, VIKOR omogućuje procjenu udaljenosti svake alternative od idealnog rješenja, što pruža dodatne informacije pri odabiru najprihvatljivijeg rješenja. Navedene karakteristike olakšavaju integraciju VIKOR metode u sustave kriznog upravljanja, kao i primjenu metode u prometnom planiranju, upravljanju razvoja infrastrukture, energetici, medicini te ostalim područjima.

Iako VIKOR metoda broji mnoge prednosti, ona ima i određena ograničenja. Kvaliteta dobivenih rezultata u velikoj mjeri ovisi o kvaliteti ulaznih podataka te pravilno određivanje težine kriterija. S obzirom na to da težine izravno utječu na konačno rangiranje, njihovo neprecizno određivanje može značajno utjecati na pouzdanost rezultata dobivenih VIKOR metodom.

Naravno mana VIKOR metode, kao i skoro svake druge, je ta da metoda zahtjeva da kriteriji budu izraženi kvantitativnim ili odgovarajuće numerički procijenjenim vrijednostima kako bi bilo moguće provesti normalizaciju i daljnje matematičke izračune. Povećanje broja alternativa i kriterija proporcionalno je s rastom složenosti izračuna, zbog čega provedba metode često postaje dosta zahtjevna kada su u pitanju složeni sustavi odlučivanja.

Jedno od važnih ograničenja odnosi se na pretpostavku da su ulazni podaci dovoljno pouzdani i da među kriterijima nema značajne međusobne ovisnosti. U stvarnim sustavima kriznog upravljanja informacije su često nepotpune, neprecizne, a ukoliko nisu onda se brzo mijenjaju, zbog čega VIKOR metoda može dati manje pouzdane rezultate. Iz tog razloga u suvremenim sustavima često se primjenjuju neizrazita (eng. *fuzzy*) proširenja VIKOR metode koja omogućuju učinkovitije modeliranje nesigurnosti i neodređenosti podataka te su u stanju znatno povećati pouzdanost proces odlučivanja u dinamičkim uvjetima [18].

3.4 TOPSIS

Razvijena 1981. godine od strane dvaju profesora Ching-Lai Hwanga i Kwangsun Yoona, metoda TOPSIS (eng. *Technique for Order Preference by Similarity to Ideal Solution*) [6] danas predstavlja jednu od najpoznatijih metoda višekriterijskog odlučivanja. Temeljena na rangiranju alternativa prema njihovoj udaljenosti od idealnog i anti-idealnog rješenja, TOPSIS metoda primjenjiva je u različitim područjima poput prometa, logistike, energetike, medicine i sustava potpore odlučivanju [6].

U području kriznog upravljanja koristi se za vrednovanje mogućih strategija djelovanja, odabir evakuacijskih ruta, raspodjelu raspoloživih resursa te određivanje prioriteta intervencija. U nastavku bit će prikazana načela rada, matematički model, postupak provedbe te prednosti i ograničenja metode.

3.4.1 Načela rada TOPSIS metode

TOPSIS je temeljen na pretpostavci da najbolju alternativu predstavlja ona koja je istodobno najbliža idealnom rješenju i najudaljenija od anti-idealnog rješenja. Idealno rješenje promatramo kao skup najboljih vrijednosti svih promatranih kriterija, dok anti-idealno rješenje predstavlja skup njihovih najmanje poželjnih vrijednosti. Temeljem udaljenosti svake alternative od te dvije referentne točke određuje se njihova relativna bliskost idealnom rješenju, koja služi kao osnova za konačno rangiranje alternativa.

Kako bi se metoda provela, potrebno je definirati skup alternativa i kriterija prema kojima će se provoditi njihovo vrednovanje. Nakon toga kriterijima je potrebno dodijeliti odgovarajuće težine koje odražavaju njihovu relativnu važnost u procesu odlučivanja. Težine se određuju različitim objektivnim ili subjektivnim metodama, dok će se u okviru ovog rada težine smatrati određenima primjenom AHP metode.

Kada se odrede težine, potrebno je provesti normalizaciju matrice odlučivanja kako bi svi kriteriji postali međusobno usporedivi, bez obzira na njihove mjerne jedinice ili raspone vrijednosti. Provedbu normalizacije slijedi izračun ponderirane normalizirane matrice, određivanje idealnog i anti-idealnog rješenja te izračun udaljenosti svake alternative od oba referentna rješenja. Dobivene udaljenosti određuju koeficijent relativne bliskosti idealnom rješenju, prema kojem se provodi konačno rangiranje svih razmatranih alternativa [7].

3.4.2 Matematički model TOPSIS metode

Primjenu započinjemo formiranjem matrice odlučivanja u kojoj svaki redak predstavlja jedan kriterij, dok svaki stupac predstavlja jednu od razmatranih alternativa. Elementi matrice predstavljaju vrijednost pojedinog kriterija za odgovarajuću alternativu te čine osnovu za daljnji matematički postupak [6].

Radi lakšeg razumijevanja te jednostavnije usporedbe s prethodno prikazanom VIKOR metodom, u ovom poglavlju koristi se isti primjer mogućih evakuacijskih ruta i isti skup kriterija.

$$F = \begin{bmatrix} f_{11} & f_{12} & \cdots & f_{1m} \\ f_{21} & f_{22} & \cdots & f_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ f_{n1} & f_{n2} & \cdots & f_{nm} \end{bmatrix}$$

Slika 3-7 Matrica odlučivanja TOPSIS metode

Objašnjenje elemenata matrice odlučivanja prikazane na slici 3-7:

- *n* – broj kriterija
- *m* – broj alternativa
- f_{ij} – vrijednost *i*-tog kriterija za *j*-tu alternativu

Primjer matrice odlučivanja korištene u ovom radu prikazan je u tablici 3-6.

Napomena: Prikazane vrijednosti predstavljaju hipotetske ekspertne ocjene na skali od 1 do 9 te služe isključivo za ilustraciju matematičkog postupka TOPSIS metode.

Tablica 3-6 Primjer matrice odlučivanja za TOPSIS metodu

Kriterij / Alternativa	Ruta A	Ruta B	Ruta C
Sigurnost	9	7	8
Vrijeme evakuacije	5	9	6
Prohodnost	6	7	9

Kao što je to bio slučaj i kod VIKOR metode, ruta A ostvaruje najveću razinu sigurnosti, ali zahtijeva dulje vrijeme evakuacije zbog obilaznog pravca. Ruta B omogućuje najbržu evakuaciju, no prolazi područjem povećanog rizika. Ruta C odlikuje se najboljom prohodnošću prometnica, ali ne postiže najbolje rezultate prema ostalim kriterijima.

Formirana matrica odlučivanja predstavlja ulazne podatke za daljnji matematički postupak TOPSIS metode. Sljedeći korak obuhvaća normalizaciju kriterijskih vrijednosti, kojom se svi kriteriji prevode na zajedničku skalu radi njihove međusobne usporedivosti [6].

3.4.3 Normalizacija matrice odlučivanja

Nad formiranom matricom potrebno je provesti normalizaciju kriterijskih vrijednosti. Cilj normalizacije je ukloniti utjecaj različitih skala mjerenja te omogućiti svakom kriteriju ravnopravno sudjelovanje u daljnjem postupku vrednovanja [6].

TOPSIS najčešće koristi vektorsku normalizaciju, pri kojoj se svaka vrijednost matrice odlučivanja dijeli korijenom sume kvadrata svih vrijednosti promatranog kriterija.

Normalizirana vrijednost određuje se izrazom [6]:

$$r_{ij} = \frac{f_{ij}}{\sqrt{\sum_{j=1}^{m} f_{ij}^2}} \tag{3-10}$$

gdje je:

- r_{ij} – normalizirana vrijednost *i*-tog kriterija za *j*-tu alternativu
- f_{ij} – vrijednost *i*-tog kriterija za *j*-tu alternativu
- m – broj alternativa

Primjenom navedenog izraza dobiva se normalizirana matrica odlučivanja:

$$\mathrm{R} = \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1m} \\ r_{21} & r_{22} & \cdots & r_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ r_{n1} & r_{n2} & \cdots & r_{nm} \end{bmatrix}$$

Slika 3-8 Normalizirana matrica

U nastavku je prikazan primjer izračuna normalizirane vrijednosti za kriterij sigurnosti i alternativu Ruta A:

$$r_{11} = \frac{9}{\sqrt{9^2 + 7^2 + 8^2}} = \frac{9}{\sqrt{194}} = 0{,}646$$

Primjenom istog postupka na sve ostale elemente matrice odlučivanja dobiva se normalizirana matrica prikazana u tablici 3-7.

Tablica 3-7 Normalizirana matrica odlučivanja

Kriterij / Alternativa	Ruta A	Ruta B	Ruta C
Sigurnost	0,646	0,503	0,574
Vrijeme evakuacije	0,420	0,755	0,504
Prohodnost	0,466	0,543	0,699

Normalizirana matrica predstavlja osnovu za sljedeći korak TOPSIS metode, u kojem se dobivene vrijednosti ponderiraju težinama pojedinih kriterija.

3.4.4 Ponderirana normalizirana matrica

U postupak vrednovanja potrebno je uključiti relativnu važnost pojedinog kriterija. To se postiže množenjem svakog elementa normalizirane matrice odgovarajućom težinom kriterija, čime se dobiva ponderirana normalizirana matrica [6].

Ponderirana normalizirana vrijednost određuje se izrazom [6]:

$$v_{ij} = w_i * r_{ij} \tag{3-11}$$

gdje je:

- v_{ij} – ponderirana normalizirana vrijednost *i*-tog kriterija za *j*-tu alternativu
- w_i – težina *i*-tog kriterija
- r_{ij} – normalizirana vrijednost *i*-tog kriterija za *j*-tu alternativu

Primjenom navedenog izraza dobiva se ponderirana normalizirana matrica:

$$V = \begin{bmatrix} v_{11} & v_{12} & \cdots & v_{1m} \\ v_{21} & v_{22} & \cdots & v_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ v_{n1} & v_{n2} & \cdots & v_{nm} \end{bmatrix}$$

Slika 3-9 Ponderirana normalizirana matrica

U ovom radu težine kriterija određene su primjenom AHP metode te su preuzete iz prethodno provedenog postupka određivanja težinskih koeficijenata. Za kriterije sigurnosti, vremena evakuacije i prohodnosti dobivene su težine w_1=0,648, w_2=0,122 i w_3=0,230 kao što se vidi iz vektora prioriteta (slika 3-5).

Primjer izračuna ponderirane normalizirane vrijednosti za kriterij sigurnosti i alternativu Ruta A:

$$v_{11} = w_1 * r_{11} = 0{,}648 * 0{,}646 = 0{,}419$$

Primjenom istog postupka na sve ostale elemente normalizirane matrice dobiva se ponderirana normalizirana matrica prikazana u tablici 3-8.

Tablica 3-8 Ponderirana normalizirana matrica odlučivanja

Kriterij / Alternativa	Ruta A	Ruta B	Ruta C
Sigurnost	0,419	0,326	0,372
Vrijeme evakuacije	0,051	0,092	0,061
Prohodnost	0,107	0,125	0,161

Formiranje ponderirane normalizirane matrice predstavlja korak prije određivanja idealnog i anti-idealnog rješenja.

3.4.5 Određivanje idealnog i anti-idealnog rješenja

Skup najboljih vrijednosti pojedinih kriterija predstavljen je kao idealno rješenje, dok anti-idealno rješenje uključuje najnepovoljnije vrijednosti pojedinih kriterija. Udaljenost pojedine alternative od dva referentna rješenja koristi se kako bi se odredile njezine relativne bliskosti idealnom rješenju [6].

Kako su svi kriteriji u promatranom primjeru kriteriji koristi, odnosno veća vrijednost kriterija označava povoljniji rezultat, idealne vrijednosti određuju se kao najveće vrijednosti pojedinog kriterija, dok anti-idealne vrijednosti određujemo kao najmanje vrijednosti.

Idealno rješenje određuje se izrazom [6]:

$$A^* = \{v_1^*,\ v_2^*, \dots, v_n^*\} \tag{3-12}$$

Pri čemu se idealna vrijednost pojedinog kriterija određuje kao:

$$v_i^* = \max_j(v_{ij}) \tag{3-13}$$

Anti-idealno rješenje određuje se izrazom [6]:

$$A^- = \{v_1^-,\ v_2^-, \dots, v_n^-\} \tag{3-14}$$

pri čemu se anti-idealna vrijednost pojedinog kriterija određuje kao:

$$v_i^- = \min_j(v_{ij}) \tag{3-15}$$

gdje je:

- A^* – idealno rješenje
- A^- – anti-idealno rješenje
- v_i^* – idealna vrijednost *i*-tog kriterija
- v_i^- – anti-idealna vrijednost *i*-tog kriterija
- v_{ij} – ponderirana normalizirana vrijednost *i*-tog kriterija za *j*-tu alternativu

Primjenom navedenih izraza na ponderiranu normaliziranu matricu iza tablice 3-8 dobivaju se idealne i anti-idealne vrijednosti prikazane u tablici 3-9.

Tablica 3-9 Tablica idealnih i anti-idealnih vrijednosti

Kriterij	Idealna vrijednost v_i^*	Anti-idealna vrijednost v_i^-
Sigurnost	0,419	0,326
Vrijeme evakuacije	0,092	0,051
Prohodnost	0,161	0,107

Na temelju dobivenih vrijednosti formiraju se idealno i anti-idealno rješenje:

$$A^* = \{0{,}419, 0{,}092, 0{,}161\}$$

$$A^- = \{0{,}326, 0{,}051, 0{,}107\}$$

Dobivena rješenja predstavljaju referentne točke za daljnji postupak TOPSIS metode. U sljedećem koraku određuje se udaljenost svake alternative od idealnog i anti-idealnog rješenja, na temelju čega će se izračunati njihova relativna bliskost idealnom rješenju.

3.4.6 Izračun udaljenosti od idealnog i anti-idealnog rješenja

Cilj izračuna udaljenosti je utvrditi koliko je pojedina alternativa udaljena od najboljeg mogućeg rješenja, ali i koliko je udaljena od najnepovoljnijeg rješenja, kako bi mogli odabrati optimalnu rutu.

Za mjerenje udaljenosti između rješenja može se primijeniti metrika Minkowskog, koja predstavlja opći oblik različitih načina mjerenja udaljenosti u višedimenzionalnom prostoru [19].

Opći izraz metrike glasi [6]:

$$d_p(A, B) = \left(\sum_{i=1}^{n} |x_i - y_i|^p \right)^{\frac{1}{p}} \tag{3-16}$$

gdje je:

- $d_p(A, B)$ – udaljenost između točaka A i B prema metrici određenoj parametrom p
- x_i – vrijednost *i*-te dimenzije, odnosno kriterija, za prvu točku
- y_i – vrijednost *i*-te dimenzije, odnosno kriterija, za drugu točku
- n – ukupan broj kriterija
- p – parametar kojim se određuje oblik metrike udaljenosti

Ovisno o vrijednosti parametra p, dobivaju se različiti načini izračuna udaljenosti. Za $p = 1$ dobiva se Manhattanova udaljenost, koja predstavlja zbroj apsolutnih razlika po svim kriterijima:

$$d_1(A,B) = \sum_{i=1}^{n} |x_i - y_i| \tag{3-17}$$

Za $p = 2$, dobiva se Euklidska udaljenost, koja predstavlja geometrijsku udaljenosti između dviju točaka:

$$d_2(A,B) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2} \tag{3-18}$$

Treći često razmatrani slučaj je $p \to \infty$, pri kojem se dobiva Čebiševljeva udaljenost:

$$d_\infty(A,B) = \max_i |x_i - y_i| \tag{3-19}$$

U ovom radu za provedbu TOPSIS metode koristi se Euklidska udaljenost, odnosno slučaj $p = 2$. Ovim pristupom su veća odstupanja dodatno naglašena kvadriranjem.

U skladu s prethodno određenim pozitivnim i negativnim idealnim rješenjem, udaljenost alternative od idealnog rješenja A^* (12) određuje se izrazom [6]:

$$D_j^* = \sqrt{\sum_{i=1}^{n} \left(v_{ij} - v_i^*\right)^2} \tag{3-20}$$

dok se udaljenost iste alternative od anti-idealnog rješenja A^- (14) određuje izrazom [6]:

$$D_j^- = \sqrt{\sum_{i=1}^{n} \left(v_{ij} - v_i^-\right)^2} \tag{3-21}$$

gdje je:

- D_j^* – udaljenost *j*-te alternative od idealnog rješenja
- D_j^- – udaljenost *j*-te alternative od anti-idealnog rješenja
- v_{ij} – ponderirana normalizirana vrijednost *i*-tog kriterija za *j*-tu alternativu
- v_i^* – idealna vrijednost *i*-tog kriterija
- v_i^- – anti-idealna vrijednost *i*-tog kriterija
- n – ukupan broj kriterija

Manja vrijednost D_j^* označava da je alternativa bliža idealnom rješenju, dok veća vrijednost D_j^- označava da je alternativa udaljenija od anti-idealnog rješenja. Sukladno tome, povoljnijom se smatra alternativa koja istodobno ostvaruje manju udaljenost od idealnog i veću udaljenost od anti-idealnog rješenja.

Za primjer odabira optimalne evakuacijske rute, udaljenosti se izračunavaju za sve tri promatrane alternative. Za Rutu A udaljenost od idealnog rješenja određuje se prema:

$$D_A^* = \sqrt{(v_{1A} - v_1^*)^2 + (v_{2A} - v_2^*)^2 + \ (v_{3A} - v_3^*)^2}$$

$$D_A^* = \sqrt{(0{,}419 - 0{,}419)^2 + (0{,}051 - 0{,}092)^2 + \ (0{,}107 - 0{,}161)^2}$$

$$D_A^* = \sqrt{0 + 0{,}001681 + 0{,}002916} = 0{,}068$$

Na isti način određuju se udaljenosti svih ostalih alternativa od idealnog i anti-idealnog rješenja. Dobivene vrijednosti prikazane su u tablici 3-10.

Tablica 3-10 Udaljenosti alternativa od idealnog i anti-idealnog rješenja

Alternativa	Udaljenost od idealnog rješenja D_j^*	Udaljenost od anti-idealnog rješenja D_j^-
Ruta A	0,068	0,093
Ruta B	0,100	0,045
Ruta C	0,056	0,072

Prema dobivenim vrijednostima da se zaključiti da je Ruta C najbliža idealnom rješenju, dok je Ruta B najudaljenija od njega. S druge strane, Ruta A ostvaruje najveću udaljenost od anti-idealnog rješenja, dok joj je ruta B najbliža. S obzirom na to da je u stvarnosti kriterija puno više i da se konačni poredak ne određuje zasebno prema jednoj od navedenih udaljenosti, potrebno je izračunati koeficijent relativne bliskosti idealnom rješenju.

3.4.7 Određivanje koeficijenta relativne bliskosti idealnom rješenju i konačno rangiranje

Za *j*-tu alternativu koeficijent relativne bliskosti određuje se izrazom [6]:

$$C_j^* = \frac{D_j^-}{D_j^* + D_j^-} \tag{3-22}$$

gdje je:

- C_j^* – koeficijent relativne bliskosti *j*-te alternative idealnom rješenju
- D_j^* – udaljenost *j*-te alternative od idealnog rješenja
- D_j^- – udaljenost *j*-te alternative od anti-idealnog rješenja

Vrijednost koeficijenta nalazi se u intervalu od 0 do 1. Veća vrijednost označava povoljniju alternativu.

Za Rutu A, temeljem prethodno izračunatih udaljenosti, koeficijent relativne bliskosti C_A^* = 0,578, za Rutu B $C_B^* = 0{,}310$, a za Rutu C $C_C^* = 0{,}563$. Dobiveni koeficijenti predstavljaju osnovu za konačno rangiranje alternativa te se iz njih jasno da zaključiti kako Ruta A pokazuje najbolju ukupnu poziciju u odnosu na idealno i anti-idealno rješenje.

3.4.8 Primjena TOPSIS metode u kriznom upravljanju

Kao i kod ostalih metoda mogućnost simultanog razmatranja većeg broja kriterija i alternativa nosi veliku važnost kada je u pitanju primjena u području kriznog upravljanja. Ono što TOPSIS razlikuje od drugih metoda, je rangiranje alternativa na način da se traži ona alternativa koja je najudaljenija od najnepovoljnijeg, odnosno anti-idealnog rješenja, a najbliža najpovoljnijem, odnosno idealnom rješenju.

Primjerice, u evakuaciji tijekom požara, pojedine rute se promatraju kao alternative, dok se sigurnost, vrijeme evakuacije ili prohodnost definiraju kao kriteriji. Kako je to i ranije zaključeno, najbrža ruta istodobno ne mora biti i najsigurnija. TOPSIS u takvoj situaciji omogućuje objedinjavanje navedenih kriterija i rangiranje ruta prema njihovoj relativnoj bliskosti idealnom rješenju. To može biti posebno korisno u situacijama kada više alternativa ostaje prihvatljivo, ali ih je potrebno međusobno prioritizirati.

3.4.9 Prednosti i ograničenja TOPSIS metode

Intuitivan logički koncept, traženje rješenja koje istodobno zadovoljava kriterij maksimalne udaljenosti od anti-idealnog stanja i minimalne udaljenosti od idealnog stanja, je jedna od najvećih prednosti TOPSIS metode. Na ovaj način ne tražimo idealno rješenje koje je najbolje po svim pojedinačnim kriterijima, već rješenje koje pruža najbolji geometrijski kompromis [6].

Prednost koju TOPSIS dijeli i s drugim metodama jest mogućnost integriranja metode u hibridni model. Sustavi kriznog upravljanja najčešće su bazirani na upravo takvim modelima, što je u radu prikazano integracijom AHP metode u svrhu određivanja težine kriterija. Također, TOPSIS je, za razliku od AHP-a ili VIKOR-a, iznimno računalno učinkovita metoda koja je

lako skalabilna, što znači da zadržava stabilnost i ne gubi puno na preciznosti s obzirom na to koliko se broj alternativa ili kriterija povećava unutar modela.

Iako TOPSIS metoda broji mnoge prednosti, postoje i određena ograničenja. Kao i kod ostalih metoda, kvaliteta dobivenih rezultata u velikoj mjeri ovisi o ulaznim podatcima. Nadalje značajan nedostatak TOPSIS-a je velika osjetljivost na ekstremne vrijednosti. S obzirom na to da smo izračun temeljili na Euklidskoj udaljenosti, preveliko odstupanje samo jednog kriterija može privući ili odbiti alternativu od referentnih točaka. Ono što često nije slučaj u složenim i realnim sustavima kriznog upravljanja, a što TOPSIS pretpostavlja, je stroga neovisnost među kriterijima i linearan rast njihove korisnosti. U praksi pojedini kriteriji često pokazuju međusobnu ovisnost.

Još jedno ograničenje TOPSIS-a odnosi se na fenomen obrata ranga (*eng. rank reversal)*. Nalazi se u samoj formuli, a dolazi do izražaja u situacijama kada se u model naknadno doda nova alternativna ruta ili se postojeća ukloni. Tada može doći do promjene matematičkih granica sustava, odnosno novog idealnog i anti-idealnog rješenja. To za posljedicu može imati neočekivanu promjenu u međusobnom poretku preostalih ruta, što u kritčnim trenutcima kriznih situacija može stvoriti izrazito veliku nestabilnost u odlučivanju.

Kao i kod VIKOR-a, kako bi se otklonili problemi nepreciznosti ulaznih podataka u dinamičkim okruženjima kriznog upravljanja, model se često nadograđuje neizrazitim (eng. *fuzzy)* proširenjem. U konačnici, unatoč navedenim teorijskim i praktičnim ograničenjima, TOPSIS ostaje iznimno moćan alat u višekriterijskom odlučivanju.

4 Eksperimentalna primjena i usporedba MCDM metoda

Nakon teorijskog prikaza metoda višekriterijskog odlučivanja, u ovom poglavlju provodi se njihova eksperimentalna primjena u simulacijskom okruženju. Cilj eksperimentalnog dijela je ispitati kako različiti postupci višekriterijskog odlučivanja utječu na dinamičko okruženje u kojem se stanje sustava kontinuirano mijenja. Posebna pozornost posvećuje se usporedbi metoda te njihovoj sposobnosti donošenja odluka na temelju isto skupa kriterija i ulaznih podataka.

Za provedbu eksperimenta koristi se računalno simulacijsko okruženje StarCraft II Learning Environment (SC2LE) [8]. Okruženje omogućuje promatranje sustava u kojem se raspoloživi resursi, položaj jedinica, stanje protivnika i druge relevantne varijable mijenjaju tijekom vremena. Na temelju promatranog stanja formira se problem višekriterijskog odlučivanja, nakon čega se primjenjuje odabrana MCDM metoda kako bi se odredila najbolja alternativa u tom trenutku simulacije.

Na ovaj način MCDM metode nisu promatrane samo kroz konačno rangiranje unaprijed definiranih alternativa, već kao dio dinamičkog procesa odlučivanja. Takav pristup omogućuje ispitivanje ponašanja metoda u uvjetima u kojima se ulazni podaci brzo mijenjaju, što je posebno važno za njihovu potencijalnu primjenu u sustavima potpore odlučivanja tijekom kriznih situacija.

4.1 Eksperimentalno okruženje

Izvorno objavljena 2010. godine Starcraft II (SC2) [20] je strateška igra u stvarnom vremenu koju je razvila i objavila tvrtka Blizzard Entertainment [10]. Temelji se na upravljanju resursima, izgradnji objekata, proizvodnji jedinica i donošenju odluka u uvjetima istodobnog djelovanja protivnika.

Nekoliko godina poslije, najavom suradnje Blizzard Entertainmenta i DeepMinda [9], britansko-američkog istraživačkog labaratorija za umjetnu inteligenciju u vlasništvu tvrtke Alphabet (Google) [21], SC2 dobiva posebnu ulogu u istraživanju umjetne inteligencije. 2017. objavljen je SC2LE, koji uključuje Blizzardov programski API za pristup igri te programske

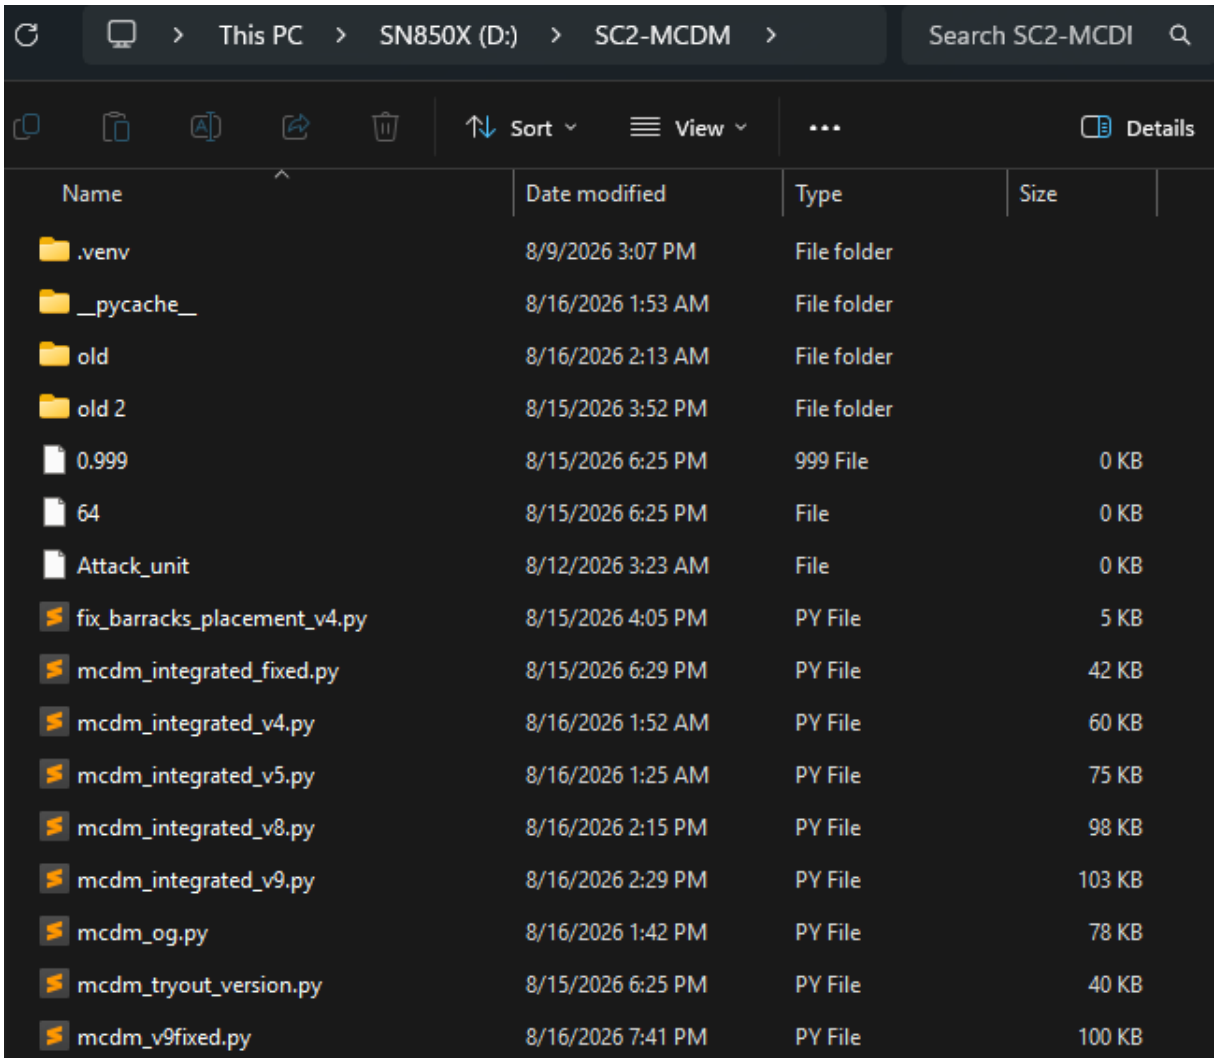
alate koje je razvio DeepMind, među kojima se nalazi PySC2 [8], Python sučelje namijenjeno povezivanju istraživačkih agenata s okruženjem StarCraft II.

Odabir SC2LE kao eksperimentalnog okruženja povezan je s njegovim karakteristikama koje ga čine pogodnim za istraživanje donošenja odluka. Sustav uključuje velik broj mogućih akcija, upravljanje ograničenim resursima, vremensku dinamiku, djelomično opažanje prostora i potrebu za istodobnim planiranjem više ciljeva. Upravo su te karakteristike prepoznate u radu kojim je predstavljen SC2LE kao izazovno okruženje za istraživanje učenja i autonomnog donošenja odluka.

U ovom radu SC2LE se ne koristi kao izravna simulacija stvarnog kriznog događaja, već kao kontrolirano eksperimentalno okruženje u kojem se može ispitati ponašanje metoda višekriterijskog odlučivanja u dinamičkom sustavu. U nastavku su opisani način instalacije i konfiguracije korištenih programskih komponenti, postavka simulacijskog scenarija te arhitektura razvijenog agenta.

4.1.1 Instalacija i konfiguracija okruženja

Za provedbu eksperimenta korišten je operacijski sustav Windows, dok je programski dio razvijen u programskom jeziku Python. Za izolaciju potrebnih programskih paketa korišteno je virtualno Python okruženje (.venv), čime je omogućeno odvajanje ovisnosti eksperimentalnog sustava od ostalih Python instalacija na računalu. Verzija Pythona korištenog u okruženju projekta je Python 3.11.9.



Slika 4-1 Programski direktorij

Komunikacija između razvijenog agenta i igre ostvarena je korištenjem biblioteke PySC2, odnosno Python sučelja za SC2 API. PySC2 omogućuje agentu pristup opažanjima igre te slanje akcija prema simulacijskom okruženju. U implementaciji korištenoj u ovom radu aktiviran je RAW action space, čime se omogućuje izravnije upravljanje jedinicama pomoću njihovih jedinstvenih oznaka (eng. *unit tags*).

Za pokretanje eksperimenta potrebno je imati instaliran SC2 zajedno s odgovarajućim verzijama potrebnih programskih paketa. Programska implementacija agenta nalazi se unutar zasebnog programskog direktorija (slika 4-1), iz kojeg se pokreće Python skripta. Nakon aktivacije virtualnog okruženja, eksperiment se pokreće naredbom:

- python ime_datoteke.py

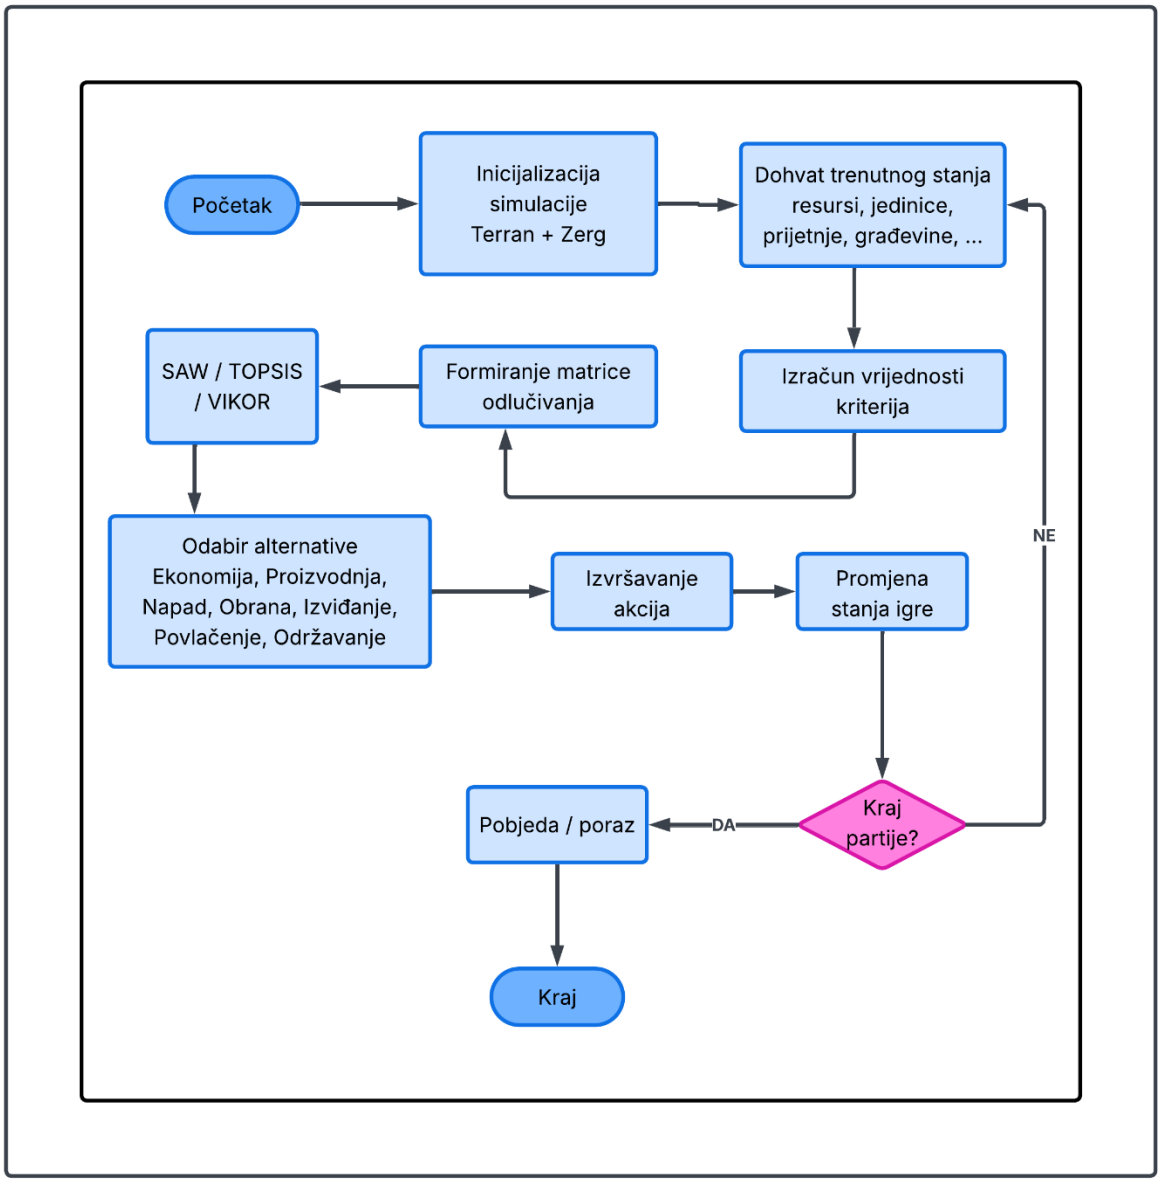
Implementacija dodatno omogućuje odabir MCDM metode i drugi eksperimenata putem naredbenog retka (eng. *command prompt - CMD*). Na taj način nije potrebno mijenjati programski kod za svako pojedinačno izvođenje, već se metode mogu međusobno uspoređivati promjenom odgovarajućeg parametra pri pokretanju.

4.1.2 Postavke i konfiguracija simulacijskog scenarija

Eksperimentalni scenarij postavljen je unutar standardnog 1v1 okruženja igre StarCraft II, u kojem svaka strana upravlja jednom od tri dostupne rase — Terran, Protoss ili Zerg. Svaka od tih rasa ima različit skup jedinica, građevina i mehanika razvoja, ali dijeli istu osnovnu strukturu partije: prikupljanje resursa (minerala i plina), izgradnju baze i proizvodnih objekata, proizvodnju vojnih jedinica te njihovo korištenje u napadu ili obrani. Upravo ta zajednička struktura — upravljanje ograničenim resursima, potreba za istodobnim planiranjem više ciljeva (ekonomskih i vojnih) te donošenje odluka pod vremenskim pritiskom uz nepotpuno poznavanje stanja protivnika — čini scenarij strukturno sličnim problemu kriznog odlučivanja opisanom u uvodu rada.

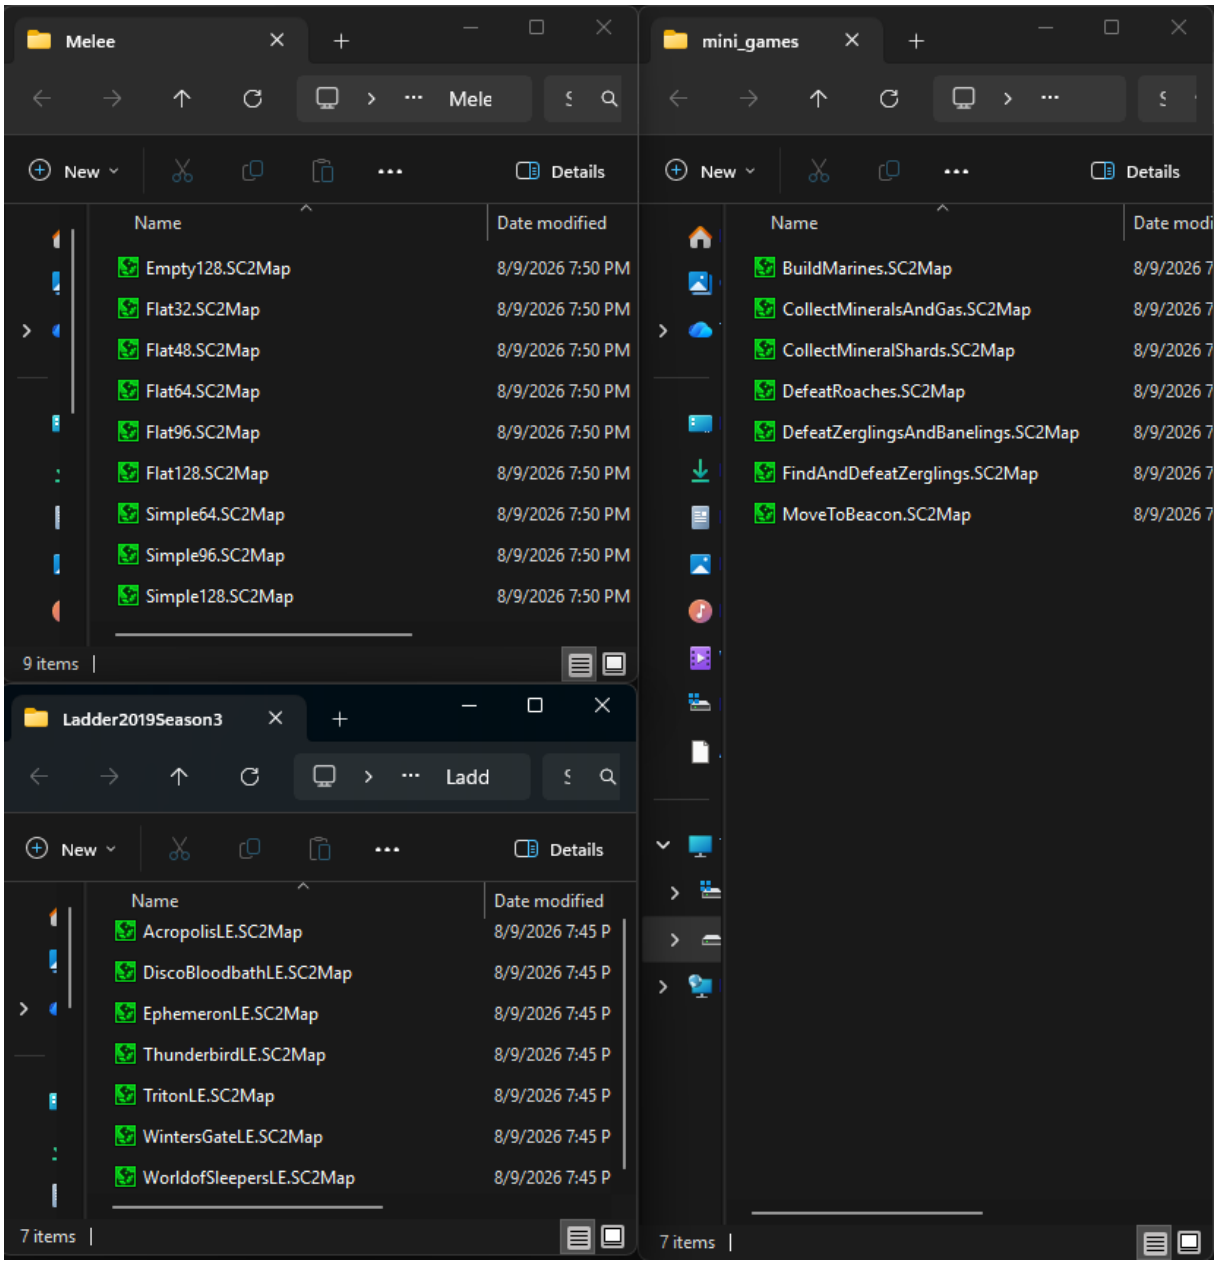
U ovom je radu odabrano da razvijeni agent upravlja rasom Terran, tehnološki svestranom rasom s naglaskom na mobilnost jedinica, popravljanje oštećenih jedinica i postupnu nadogradnju baze, dok je protivnička strana predstavljena rasom Zerg, koja se oslanja na brzo širenje, jeftinu proizvodnju jedinica i brojčanu nadmoć. Izbor ovih dviju rasa nije presudan za rezultate rada jer MCDM metode implementirane u agentu ne ovise o specifičnim mehanikama pojedine rase, već o općenitim kriterijima poput vojnog učinka, hitnosti i raspoloživih resursa (opisanima detaljnije u poglavlju 4.2). Kombinacija Terran–Zerg odabrana je kao reprezentativan i dovoljno dinamičan par u kojem se ravnoteža ekonomije i vojne snage brzo mijenja, što omogućuje jasnije praćenje kako MCDM metoda reagira na promjenu stanja.

Igra se izvodi u načinu rada protiv ugrađenog računalno upravljanog protivnika (eng. *built-in AI*), pri čemu se razina njegove težine može odrediti prije pokretanja eksperimenta, u rasponu od *very_easy* do *very_hard*. Na taj način moguće je provoditi eksperimente s različitim razinama složenosti protivničkog ponašanja te provjeriti je li ponašanje agenta osjetljivo na promjenu vanjskih uvjeta, a ne samo na odabranu MCDM metodu.



Slika 4-2 Dijagram toka eksperimentalnog postupka i procesa odlučivanja agenta

Karte korištene u eksperimentima nalaze se u direktoriju Maps instalacije igre StarCraft II. Organizacija direktorija omogućuje pohranu različitih skupina karata, među kojima su u korištenoj instalaciji prisutni direktoriji Ladder2019Season3, Melee i mini_games, što je prikazano na slici 4-3.



Slika 4-3 Direktorij s kartama SC2

Izbor karte nije trajno određen programskim kodom. U razvijenoj implementaciji naziv karte može se zadati prilikom pokretanja programa pomoću parametra --map, dok se dodatnim parametrom --map_dir može odrediti poddirektorij u kojem se karta nalazi. Program pri pokretanju provjerava dostupnost odabrane karte te prema potrebi pretražuje direktorij s kartama kako bi pronašao odgovarajuću .SC2Map datoteku. Na taj način omogućeno je korištenje različitih karata bez potrebe za izmjenom osnovne programske logike.

Osim izbora karte i protivnika, parametri simulacije definirani su tako da se mogu mijenjati izravno prilikom pokretanja programa. U tu svrhu implementacija koristi konfiguracijske argumente naredbenog retka, čime se pojedinačni eksperiment može prilagoditi bez promjene izvornog koda.

Primjer načina pokretanja koda s parametrima:

- python mcdm_integrated_v9.py –mcdm=topsis –map=Simple64 –episodes=10 –difficulty=easy --random_seed=42

Među parametrima se nalaze broj epizoda, razina težine protivnika, korištena MCDM metoda, način normalizacije, parametar v metode VIKOR, vremenski korak simulacije, slučajno sjeme te parametri povezani sa zapisivanjem rezultata. Svi parametri definirani su u tablici 4-1. Naravno parametre se može i mijenjati direktnu u kodu (kod 4-3).

Tablica 4-1 Parametri konfiguracije simulacijskog scenarija

Parametar	Opis	Moguće vrijednosti
--episodes	Broj epizoda simulacije	Cijeli broj
--visualize	Uključivanje vizualnog prikaza simulacije	True / False
--difficulty	Razina težine računalno upravljanog protivnika	very_easy, easy, medium, medium_hard, hard, harder, very_hard

--step_mul	Broj game loopova između uzastopnih koraka agenta	Cijeli broj
--quiet	Smanjenje detaljnog ispisa u naredbenom retku	True / False
--idle_speedup	Ubrzavanje simulacije tijekom neaktivnosti	True / False
--mcdm	Odabir metode višekriterijskog odlučivanja	saw, topsis, vikor, none
--normalization	Način normalizacije vrijednosti kriterija	classic, shared
--vikor_v	Parametar v metode VIKOR	Realni broj od 0 do 1
--decision_log	Zapis rezultata odlučivanja	Putanja do CSV datoteke
--map	Odabir korištene karte	Naziv karte / .SC2Map datoteka
--map_dir	Poddirektorij u kojem se karta nalazi	Naziv poddirektorija
--raw_resolution	Rezolucija RAW koordinatnog prostora	Cijeli broj
--profile	Profil operativnog ponašanja vlastitog agenta	easy, medium, hard
--random_seed	Početno slučajno sjeme	Cijeli broj; -1 za slučajno sjeme

```python
def _flag(define, name, default, description):
    # Guarded so the module can also be imported by a batch runner that
    # already defines flags, instead of raising DuplicateFlagError.
    if name not in FLAGS:
        define(name, default, description)


_flag(flags.DEFINE_integer, "episodes", 1, "Number of episodes to play.")
_flag(flags.DEFINE_boolean, "visualize", False, "Render the pysc2 visualizer.")
_flag(flags.DEFINE_string, "difficulty", "easy", "Built-in bot difficulty.")
_flag(flags.DEFINE_integer, "step_mul", 8, "Game loops per agent step.")
_flag(flags.DEFINE_boolean, "quiet", False, "Suppress per-action logging.")
_flag(flags.DEFINE_boolean, "idle_speedup", True,
      "Advance more game loops per step while nothing needs doing.")
_flag(flags.DEFINE_string, "mcdm", "saw",
      "Aggregation method: saw, topsis, vikor, or none (ablation).")
_flag(flags.DEFINE_string, "normalization", "classic",
      "classic = SAW/VIKOR linear, TOPSIS vector; shared = linear for all.")
_flag(flags.DEFINE_float, "vikor_v", 0.5, "VIKOR weight of group utility.")
_flag(flags.DEFINE_string, "decision_log", "",
      "CSV path for per-decision matrices, scores and rankings.")
_flag(flags.DEFINE_string, "map", "Simple64", "Map name or .SC2Map file name.")
_flag(flags.DEFINE_string, "map_dir", "",
      "Subfolder of StarCraft II/Maps holding the map, if auto-detection fails.")
_flag(flags.DEFINE_integer, "raw_resolution", 64,
      "Raw coordinate grid. Positions are scaled into this grid, so the "
      "agent calibrates its own distances against it at game start.")
_flag(flags.DEFINE_string, "profile", "",
      "Build profile: easy, medium, hard. Empty = follow --difficulty.")
_flag(flags.DEFINE_integer, "random_seed", -1,
      "SC2 random seed; use the same value across methods for paired runs.")
```

Kod 4-1 Definicija konfiguracijskih parametara u programskoj implementaciji

Navedeni parametri omogućuju promjenu eksperimentalnih uvjeta bez izmjene osnovne logike razvijenog agenta. Posebno je značajan parametar --mcdm, kojim se odabire metoda višekriterijskog odlučivanja, dok ostali parametri omogućuju kontrolu uvjeta u kojima se metoda ispituje. Za međusobnu usporedbu MCDM metoda potrebno je ostale relevantne parametre, poput karte, težine protivnika, profila agenta i slučajnog sjemena, zadržati jednakima. Na taj se način osiguravaju usporedivi uvjeti izvođenja, pri čemu se kao glavna promjenjiva veličina može promatrati odabrana metoda višekriterijskog odlučivanja.

4.1.3 Arhitektura i implementacija razvijenog agenta

Razvijeni agent organiziran je kao zatvorena petlja odlučivanja u kojoj se stanje simulacije kontinuirano prikuplja, obrađuje i koristi za odabir sljedeće akcije. Osnovna ideja implementacije je odvojiti proces donošenja strateške odluke od njezina izvršavanja u igri. MCDM metoda određuje koji je tip aktivnosti trenutno najvažniji, dok izvršni dio agenta provjerava može li se odabrana aktivnost u trenutnom stanju igre zakonito provesti.

Za svaki korak simulacije agent najprije preuzima trenutno opažanje igre. U njemu se nalaze podaci o jedinicama, njihovim tipovima, pripadnosti igraču, položaju i drugim značajkama potrebnima za donošenje odluke. Umjesto višestrukog prolaska kroz sirove podatke igre, implementacija ih na početku koraka organizira u objekt Snapshot. Na taj se način informacije o vlastitim i protivničkim jedinicama te njihovim oznakama (eng. *unit tags*) mogu naknadno dohvaćati iz pripremljenih struktura.

Relevantni podaci iz trenutnog stanja zatim se pretvaraju u skup vrijednosti koji predstavlja stanje sustava za potrebe višekriterijskog odlučivanja. Pri tome se uzimaju u obzir elementi poput broja radnika, vojnih jedinica, vojarni, raspoloživih minerala, slobodnih resursa, broja protivničkih jedinica i prijetnji unutar vlastite baze. Ti se podaci koriste za određivanje vrijednosti kriterija za svaku dostupnu alternativu.

Alternativa u ovom sustavu ne predstavlja pojedinačnu naredbu poput pomicanja jedne jedinice, već strateški prioritet. Agent među definiranim alternativama bira, primjerice, ekonomiju, proizvodnju, napad, obranu, izviđanje, povlačenje ili održavanje. Na taj je način MCDM sloj usmjeren na odgovor na pitanje što je u trenutnom stanju potrebno napraviti, dok se kasnije izvršni sloj brine o tome kako tu odluku provesti u igri.

Nakon formiranja matrice odlučivanja primjenjuje se odabrana MCDM metoda. Implementacija sadrži funkcije za SAW [4], TOPSIS i VIKOR. SAW normalizira vrijednosti kriterija te izračunava ponderirani zbroj, TOPSIS određuje udaljenost alternativa od idealnog i anti-idealnog rješenja, dok VIKOR određuje kompromisno rješenje na temelju grupne korisnosti i individualnog žaljenja.

Primjer implementacije TOPSIS metode prikazan je u Kodu 4-2:

```
def topsis(matrix, weights, types, feasible, scheme="vector", **kwargs):
    """Technique for Order Preference by Similarity to Ideal Solution."""
    sub = submatrix(matrix, feasible)

    if scheme == "vector":
        norm = normalise_vector(sub, types)
        orientation = types
    else:
        norm = normalise_linear(sub, types)
        orientation = (1,) * len(types)

    cols = len(weights)
    weighted = [[weights[j] * row[j] for j in range(cols)] for row in norm]

    best = []
    worst = []
    for j in range(cols):
        column = [row[j] for row in weighted]
        if orientation[j] > 0:
            best.append(max(column))
            worst.append(min(column))
        else:
            best.append(min(column))
            worst.append(max(column))

    scores = {}
    separations = {}

    for k, i in enumerate(feasible):
        d_best = math.sqrt(
            sum((weighted[k][j] - best[j]) ** 2 for j in range(cols)))
        d_worst = math.sqrt(
            sum((weighted[k][j] - worst[j]) ** 2 for j in range(cols)))

        total = d_best + d_worst
        # Every alternative identical -> all equally close to the ideal.
        scores[i] = 1.0 if total <= 1e-12 else d_worst / total
        separations[i] = (d_best, d_worst)

    return MethodResult(scores, higher_better=True,
                        meta={"separations": separations})
```

Kod 4-2 Implementacija TOPSIS metode

Nakon izračuna rezultata pojedinih alternativa, agent određuje alternativu s najpovoljnijim rezultatom te je prosljeđuje izvršnom dijelu sustava. Prije izvršavanja odabrane aktivnosti provjeravaju se potrebni uvjeti. Time se odvaja proces donošenja odluke od samog izvršavanja akcije, odnosno odabir strateškog prioriteta ne znači automatski i izvršavanje konkretne naredbe u igri.

Izvršni dio implementacije zatim odabranu alternativu pretvara u konkretne akcije nad jedinicama i objektima u igri. Ovisno o odabranoj aktivnosti, agent može upravljati radnicima, izgradnjom objekata, proizvodnjom vojnih jedinica, obrambenim položajima ili napadom protivničkih jedinica. Pri tome se koriste podaci o trenutno dostupnim jedinicama i njihovim oznakama, čime se omogućuje povezivanje odluke donesene na strateškoj razini s konkretnom jedinicom koja će je izvršiti.

Nakon izvršavanja akcije stanje igre se ponovno opaža te se cijeli postupak ponavlja. Promjena stanja tako utječe na vrijednosti kriterija u sljedećem ciklusu odlučivanja, zbog čega agent ne donosi sve odluke unaprijed, već ih prilagođava razvoju situacije tijekom simulacije. Takva struktura omogućuje promatranje MCDM-a kao kontinuiranog procesa odlučivanja u dinamičkom okruženju.

Na taj je način razvijeni agent podijeljen na nekoliko međusobno povezanih funkcionalnih cjelina: prikupljanje i obradu stanja igre, formiranje ulaznih podataka za MCDM, izračun prioriteta, odabir alternative te izvršavanje odabrane aktivnosti. Ovakva podjela omogućuje da se metoda višekriterijskog odlučivanja promijeni bez potrebe za promjenom ostatka sustava, što je posebno važno za eksperimentalnu usporedbu različitih MCDM pristupa.

4.2 Primjena MCDM metoda u razvijenom agentu

Opis arhitekture i način rada razvijenog agenta čine podlogu za opis implementacije MCDM metoda primjenjenih u simulacijskom sustavu. U ovom dijelu rada opisani su izbor metoda, definirane alternative i kriteriji, način određivanja težina te postupak izračuna konačnog prioriteta pojedinih alternativa.

4.2.1 Odabir MCDM metoda

Teorijskim dijelom rada obrađene su različite metode višekriterijskog odlučivanja, među kojima je i AHP. Međutim, za eksperimentalnu implementaciju odabrane su metode SAW, TOPSIS i VIKOR. Razlog takvog odabira proizlazi iz načina na koji je definiran problem odlučivanja u razvijenom agentu. U svakom trenutku simulacije potrebno je, na temelju dostupnih podataka i prethodno definiranih težina kriterija, rangirati više mogućih strateških aktivnosti i odrediti onu koja predstavlja najpovoljniji izbor.

AHP je posebno prikladan za strukturiranje hijerarhijskog problema odlučivanja i određivanje relativne važnosti kriterija putem međusobnih usporedbi. Međutim, u okruženju videoigre u stvarnom vremenu, numeričke vrijednosti kriterija u matrici odlučivanja mijenjaju se u svakom koraku simulacije (eng. *game loop*). Primjena AHP-a za izravno rangiranje alternativa zahtijevala bi da agent u svakom koraku računa nove matrice međusobnih usporedbi alternativa za svaki pojedini kriterij te provjerava indeks konzistentnosti, što bi uzrokovalo preveliku računalnu složenost i latenciju. S druge strane, metoda SAW (eng. *Simple Additive Weighting*) [4] omogućuje da se prethodno definirani i stabilni vektori težina kriterija izravno i trenutačno primijene na normalizirane podatke koji pristižu iz PySC2 okruženja. Kao jednostavnija metoda agregacije SAW izračunava ukupnu vrijednost alternative kao čisti ponderirani zbroj, što ga čini računski izuzetno učinkovitim za donošenje odluka u milisekundama [22]. Uz SAW uključene su prethodno definirane metode VIKOR i TOPSIS.

Odabir navedenih metoda omogućuje da se u eksperimentu usporede različiti načini definiranja najboljeg rješenja. SAW odabir temelji na ukupnoj ponderiranoj vrijednosti, TOPSIS na udaljenosti od idealnog i anti-idealnog rješenja, dok VIKOR traži kompromisno rješenje između grupne korisnosti i individualnog žaljenja. Na taj način razlike između metoda mogu utjecati i na konačni izbor strateške aktivnosti agenta.

U implementaciji se metoda ne odabire promjenom izvornog koda, već konfiguracijskim parametrom --mcdm. Vrijednost parametra može biti saw, topsis, vikor ili none, čime je omogućeno izvođenje različitih konfiguracija nad istim simulacijskim okruženjem.

4.2.2 Definicija alternativa i kriterija

Problem odlučivanja u razvijenom agentu definiran je kao matrica koja povezuje sedam mogućih strateških alternativa sa šest kriterija odlučivanja. Svaka alternativa predstavlja mogući strateški smjer djelovanja agenta, dok kriteriji opisuju različite aspekte njegove prikladnosti u trenutnom stanju simulacije. U implementaciji se matrica formira za svako novo stanje igre, čime se vrijednosti kriterija mogu mijenjati tijekom izvođenja.

Definirane alternative su:

- EKONOMIJA – usmjeravanje aktivnosti prema razvoju gospodarstva, odnosno proizvodnji SCV jedinica (eng. *Space Construction Vehicle, osnovna radnička jedinica rase Terran zadužena za sakupljanje resursa i izgradnju)* i iskorištavanju radne snage;
- PROIZVODNJA – povećavanje proizvodnih kapaciteta ili proizvodnja vojnih jedinica;
- NAPAD – usmjeravanje raspoložive vojske prema napadačkim aktivnostima;
- OBRANA – reakcija na postojeću prijetnju i zaštita vlastite baze;
- IZVIĐANJE – prikupljanje dodatnih informacija o protivničkim jedinicama i stanju prostora;
- POVLAČENJE – smanjivanje izloženosti vlastitih vojnih jedinica kada odnos snaga nije povoljan;
- ODRŽAVANJE – aktivnosti povezane s održavanjem funkcionalnosti sustava, poput upravljanja resursima, radnicima i drugim pomoćnim aktivnostima.

Za opisivanje navedenih alternativa u matrici odlučivanja koristi se šest kriterija sa težinama:

- ekonomski učinak (0,20) – potencijal za ekonomski rast i stabilnost baze
- vojni učinak (0,25) – trenutačna borbena moć i kapacitet proizvodnje vojske
- hitnost (0,30) – vremenski pritisak i neposredna ugroza baze
- trošak minerala (0,10) – potrebna resursna ulaganja za provođenje akcije

- rizik (0,10) – vjerojatnost gubitka jedinica ili struktura
- latencija (0,05) - vremensko kašnjenje do realizacije odabrane odluke

```
CRITERIA = ("ekonomski_ucinak", "vojni_ucinak", "hitnost",
            "trosak_min", "rizik", "latencija")

# +1 = benefit (more is better), -1 = cost (less is better)
CRITERION_TYPE = (1, 1, 1, -1, -1, -1)

CRITERION_WEIGHT = (0.20, 0.25, 0.30, 0.10, 0.10, 0.05)

ACTIONS = (
    "EKONOMIJA",
    "PROIZVODNJA",
    "NAPAD",
    "OBRANA",
    "IZVIDANJE",
    "POVLACENJE",
    "ODRZAVANJE",
)
```

Kod 4-3 Definicija kriterija, njihovih težina i alternativa u programskoj implementaciji

Prva tri kriterija definirana su kao benefit kriteriji, odnosno veća vrijednost predstavlja povoljniji rezultat. Preostala tri definirana su kao cost kriteriji, kod kojih je povoljnija manja vrijednost. Takva orijentacija kriterija izravno je definirana u programskoj implementaciji i koristi se tijekom normalizacije podataka.

Težine kriterija u implementaciji iznose 0,20, 0,25, 0,30, 0,10, 0,10 i 0,05, pri čemu njihov zbroj iznosi 1,00. Najveća težina dodijeljena je kriteriju hitnosti, nakon čega slijede vojni i ekonomski učinak. Trošak minerala i rizik imaju jednaku težinu, dok latencija ima najmanju težinu. Te su težine u programskom kodu definirane kao zajednički ulaz za MCDM metode.

Važno je naglasiti da se vrijednosti kriterija ne zadaju jednom za cijelu simulaciju. One se izračunavaju iz trenutačnog stanja igre. Za njihovo određivanje koriste se podaci kao što su broj radnika i vojnih jedinica, broj protivničkih jedinica, količina minerala, broj vojarni, broj prijetnji u području vlastite baze te raspoloživi resursi.

Primjerice, ekonomski učinak alternative povezan je s nedostatkom radnika i raspoloživim resursima, dok se vojni učinak između ostalog određuje prema trenutačnoj vojnoj snazi. Kod napada se dodatno uzima u obzir odnos vlastite vojske i protivničkih jedinica. Kod obrane se posebno povećava vrijednost hitnosti kada su protivničke jedinice prisutne u području vlastite baze.

Na taj način ista alternativa može imati različitu vrijednost kriterija u različitim trenucima simulacije. Primjerice, alternativa NAPAD može imati nisku vrijednost vojnog učinka kada agent raspolaže malim brojem jedinica, dok njezina vrijednost raste razvojem vojske. S druge strane, vrijednost alternative OBRANA raste kada se u području vlastite baze pojavi prijetnja. Time se matrica odlučivanja prilagođava promjenama u okolini, umjesto da ostaje nepromijenjena tijekom cijele epizode.

4.2.3 Formiranje matrice odlučivanja

Nakon definiranja alternativa, kriterija i njihovih težina, potrebno je vrijednosti dobivene iz trenutnog stanja simulacije organizirati u matricu odlučivanja. U implementaciji je matrica definirana tako da svaki redak predstavlja jednu alternativu, dok stupci odgovaraju kriterijima. Vrijednosti se pritom zadržavaju u svojim izvornim mjernim jedinicama, a njihova se normalizacija provodi tek unutar odabrane MCDM metode.

Matrica se generira unutar funkcije decision_matrix() (kod 4-4 i kod 4-5). Za svaku alternativu definirana je zasebna kombinacija vrijednosti kriterija, pri čemu se vrijednosti izračunavaju na temelju trenutnog stanja simulacije. U izračun ulaze podaci kao što su broj vlastitih vojnih jedinica i radnika, količina minerala, broj izgrađenih i trenutno građenih vojarni, broj protivničkih jedinica te broj prijetnji u području vlastite baze.

```
def decision_matrix(self, s):
    """One row per alternative, in the natural units of each criterion.

    Columns: economic effect, military effect, urgency (all benefit,
    0..1), mineral cost (minerals), risk (0..1), latency (game loops
    until the action pays off).
    """
    workers = s["workers"]
    army = s["army"]
    enemy = s["enemy"]
    minerals = s["minerals"]
    barracks = s["barracks"]
    threats = len(s["threats_home"])
    supply = s["supply_left"] + s["supply_pending"]

    cfg = self.cfg
    worker_target = float(cfg["worker_target"])
    max_barracks = float(cfg["max_barracks"])
    attack_min = float(cfg["attack_min"])

    worker_deficit = clamp((worker_target - workers) / worker_target)
    barracks_deficit = clamp((max_barracks - barracks) / max_barracks)
    mineral_surplus = clamp(minerals / 400.0)
    force_ratio = (army + 1.0) / (enemy + 1.0)
    supply_pressure = clamp(1.0 - supply / 8.0)

    can_expand = barracks + len(s["barracks_building"]) < max_barracks
```

Kod 4-4 Izračun ulaznih vrijednosti za formiranje matrice odlučivanja

```
    return [
        # EKONOMIJA
        [worker_deficit,
         0.05,
         worker_deficit * (1.0 if minerals >= SCV_COST else 0.4),
         float(SCV_COST),
         0.10,
         300.0],
        # PROIZVODNJA
        [0.05,
         clamp(0.6 * barracks_deficit + 0.4 * mineral_surplus),
         mineral_surplus,
         float(BARRACKS_COST if can_expand else MARINE_COST),
         0.20,
         1030.0 if can_expand else 400.0],
        # NAPAD
        [0.0,
         clamp(army / attack_min) * clamp(force_ratio / 1.5),
         clamp(army / attack_min),
         0.0,
         clamp(1.0 - force_ratio / 2.0),
         200.0],
        # OBRANA
        [0.15,
         clamp(threats / max(1.0, army * 0.5)) if threats else 0.0,
         1.0 if threats else 0.0,
         0.0,
         clamp(threats / max(1.0, float(army))) * 0.5,
         0.0],
        # IZVIDANJE
        [0.0,
         0.10,
         0.30 if s["enemy_seen"] == 0 else 0.05,
         0.0,
         0.30,
         600.0],
        # POVLACENJE
        [0.05,
         clamp((enemy - army) / max(1.0, float(enemy))) if army else 0.0,
         clamp((enemy - army) / max(1.0, float(enemy))) if army else 0.0,
         0.0,
         0.20,
         150.0],
        # ODRZAVANJE
        [0.20,
         0.10,
         clamp(0.6 * supply_pressure + 0.4 * mineral_surplus),
         float(DEPOT_COST),
         0.05,
         470.0],
    ]
```

Kod 4-5 Formiranje vrijednosti kriterija za pojedine alternative

Posebnost ovakvog pristupa je u tome što matrica nije unaprijed zadana jednom vrijednošću za cijelu simulaciju. Svaki novi korak odlučivanja koristi novo stanje igre te se na temelju njega ponovno izračunavaju vrijednosti kriterija. Primjerice, povećanje broja vlastitih vojnih jedinica može promijeniti vrijednost vojnog učinka, dok pojava protivničkih jedinica u području baze utječe na vrijednosti povezane s hitnošću, rizikom i obranom.

Prije primjene MCDM metode provjerava se i izvedivost pojedinih alternativa. Funkcija available() (kod 4-6) za svaku alternativu određuje može li se ona u trenutnom stanju provesti. Primjerice, napad zahtijeva minimalan broj vojnih jedinica, obrana zahtijeva istodobno postojanje prijetnje i vlastite vojske, dok se proizvodnja može odabrati ako postoji mogućnost izgradnje dodatne vojarne ili proizvodnje jedinica iz postojeće vojarne. Alternativa održavanja ostaje dostupna kao osnovna aktivnost.

```
def available(self, s):
    cfg = self.cfg
    army = s["army"]
    threats = len(s["threats_home"])

    can_expand = (s["barracks"] + len(s["barracks_building"])
                  < cfg["max_barracks"])
    can_train = s["barracks"] > 0

    return {
        "EKONOMIJA": s["workers"] < cfg["worker_target"],
        "PROIZVODNJA": can_expand or can_train,
        "NAPAD": army >= cfg["attack_min_napad"],
        "OBRANA": threats > 0 and army > 0,
        "IZVIDANJE": (s["enemy_seen"] == 0
                      and s["workers"] >= cfg["scout_min_workers"]),
        "POVLACENJE": army > 0 and threats == 0,
        "ODRZAVANJE": True,
    }
```

Kod 4-6 Funkcija available

Na temelju rezultata provjere formira se skup izvedivih alternativa. Ako je moguće provesti barem jednu od definiranih aktivnosti, MCDM metoda se primjenjuje samo na taj skup. Ako nijedna alternativa nije označena kao izvediva, implementacija kao pričuvnu mogućnost

odabire alternativu ODRŽAVANJE. Na taj način metoda ne rangira aktivnosti koje agent u danom trenutku ne može izvršiti.

Nakon izdvajanja izvedivih alternativa, matrica, težine kriterija, njihova orijentacija te konfiguracija odabrane metode prosljeđuju se MCDM sloju. Implementacija koristi isti ulazni problem za sve tri metode, dok se postupak obrade razlikuje ovisno o tome je li odabran SAW, TOPSIS ili VIKOR. Time je struktura modela odvojena od pojedinačnog postupka agregacije, što omogućuje promjenu metode bez promjene načina prikupljanja podataka iz simulacije.

Važna značajka implementacije je da se normalizacija ne provodi pri samom formiranju matrice. Matrica ostaje u prirodnim jedinicama kriterija, dok pojedina metoda primjenjuje vlastiti postupak normalizacije. Za SAW i VIKOR koristi se linearna normalizacija, dok je za TOPSIS zadano korištenje vektorske normalizacije. Time je omogućeno da način normalizacije bude zaseban element eksperimentalne konfiguracije.

Na kraju postupka MCDM metoda vraća rezultate i rangiranje izvedivih alternativa. Prva alternativa u dobivenom rangiranju postaje odabrani strateški prioritet te se prosljeđuje izvršnom dijelu agenta. Nakon izvršavanja akcije stanje simulacije se ponovno očitava i postupak formiranja matrice započinje iznova. Time se ostvaruje kontinuirana veza između promjene stanja igre i donošenja novih odluka.

4.2.4 Primjena SAW metode

Osnovna ideja metode je svesti vrijednosti različitih kriterija na usporediv oblik, nakon čega se normalizirane vrijednosti ponderiraju pripadajućim težinama i zbrajaju. Konačni rezultat predstavlja ukupnu vrijednost alternative, pri čemu veći rezultat označava povoljniju alternativu.

U razvijenom agentu SAW se primjenjuje nad matricom odlučivanja prethodno formiranom iz trenutnog stanja simulacije. Prije izračuna rezultata iz matrice se izdvajaju samo izvedive alternative. Na taj se način u rangiranje ne uključuju aktivnosti koje agent u trenutnom stanju ne može provesti.

Za benefit kriterije, kod kojih veća vrijednost predstavlja povoljniji rezultat, normalizacija se provodi prema izrazu [4]:

$$r_{ij} = \frac{x_{ij} - min_i(x_{ij})}{max_i(x_{ij}) - min_i(x_{ij})} \tag{4-1}$$

dok se za cost kriterije, kod kojih je manja vrijednost povoljnija, koristi:

$$r_{ij} = \frac{max_i(x_{ij}) - x_{ij}}{max_i(x_{ij}) - min_i(x_{ij})} \tag{4-2}$$

gdje je x_{ij} izvorna vrijednost kriterija *j* za alternativu *i*, a r_{ij} njezina normalizirana vrijednost.

Nakon normalizacije primjenjuju se težine kriterija. Ukupni rezultat alternative računa se kao:

$$S_i = \sum_{j=1}^{n} w_j r_{ij} \tag{4-3}$$

gdje je w_j težina kriterija *j*, a r_{ij} normalizirana vrijednost tog kriterija za alternativu *i*. Alternativa s najvećom vrijednošću S_i dobiva najviši prioritet.

U programskoj implementaciji postupak je izveden funkcijom saw() (kod 4-7). Funkcija najprije izdvaja izvedive alternative i nad njima provodi odabrani način normalizacije. Nakon toga se svaka normalizirana vrijednost množi pripadajućom težinom, a dobiveni se rezultati zbrajaju za svaku alternativu.

```python
def saw(matrix, weights, types, feasible, scheme="linear", **kwargs):
    """Simple Additive Weighting. Always max-min normalised - that is
    the standard SAW definition and keeps cost criteria meaningful."""
    sub = submatrix(matrix, feasible)
    norm = normalise_linear(sub, types)

    scores = {}
    for k, i in enumerate(feasible):
        scores[i] = sum(weights[j] * norm[k][j] for j in range(len(weights)))

    return MethodResult(scores, higher_better=True)
```

Kod 4-7 Implementacija SAW metode

U implementaciji je rezultat svake alternative spremljen kao njezin ukupni SAW rezultat. Budući da se matrica odlučivanja ponovno izračunava nakon promjene stanja igre, mijenjaju se i ulazne vrijednosti za SAW. Posljedično, alternativa s najvećim rezultatom ne mora biti ista u svakom trenutku simulacije.

Primjerice, kada je stanje sustava stabilno i nema neposredne prijetnje, veći rezultat mogu ostvariti alternative povezane s ekonomskim razvojem ili proizvodnjom. Pojavom prijetnje mijenjaju se vrijednosti relevantnih kriterija, zbog čega alternativa obrane može postati povoljnija. SAW tako omogućuje donošenje odluke na temelju trenutnog odnosa svih kriterija, a ne na temelju jednog izoliranog parametra.

4.2.5 Implementacija metode TOPSIS

TOPSIS metoda svaku alternativu vrednuje prema njezinoj udaljenosti od idealnog i anti-idealnog rješenja, pri čemu konačni prioritet određuje koeficijent relativne bliskosti idealnom rješenju. Matematički model metode, uključujući postupke normalizacije, određivanje idealnog i anti-idealnog rješenja te izračun udaljenosti, detaljno je opisan u poglavlju 3.4, stoga je u nastavku prikazana isključivo njezina programska implementacija.

Funkcija topsis() (kod 4-2) prima matricu odlučivanja, težine kriterija, njihovu orijentaciju, skup izvedivih alternativa te parametar scheme kojim se određuje način normalizacije. Ukoliko je odabrana vektorska normalizacija („vector“), zadržava se izvorna orijentacija kriterija te se

idealno i anti-idealno rješenje određuju posebno za benefit i cost kriterije. Ukoliko je odabrana linearna normalizacija, sve normalizirane vrijednosti već su benefit-orijentirane, zbog čega se u tom slučaju idealno rješenje jednostavno poistovjećuje s najvećom ponderiranom vrijednošću u svakom stupcu. Ovime je normalizacijska shema, kao i kod metode SAW, zaseban parametar eksperimentalne konfiguracije, a ne ugrađeno svojstvo same metode.

Nakon određivanja idealnog i anti-idealnog rješenja za svaku izvedivu alternativu izračunavaju se dvije Euklidske udaljenosti: udaljenost od idealnog rješenja i udaljenost od anti-idealnog rješenja. Koeficijent relativne bliskosti dobiva se kao omjer udaljenosti od anti-idealnog rješenja i zbroja obiju udaljenosti, pri čemu veća vrijednost koeficijenta označava povoljniju alternativu. Poseban je slučaj obrađen kada je zbroj obiju udaljenosti zanemarivo malen, odnosno kada su sve alternative praktički identične prema svim kriterijima; u tom se slučaju svakoj alternativi dodjeljuje jednaka vrijednost koeficijenta, čime se izbjegava dijeljenje s vrijednošću bliskom nuli.

Za razliku od metode SAW, kod koje se prioritet alternative određuje isključivo ponderiranim zbrojem njezinih normaliziranih vrijednosti, TOPSIS uzima u obzir i geometrijski odnos alternative prema oba krajnja rješenja. Time dvije alternative mogu ostvariti sličan ponderirani zbroj, a ipak dobiti različit TOPSIS rezultat ukoliko se razlikuju po tome koliko su blizu anti-idealnom rješenju. U kontekstu razvijenog agenta to znači da alternativa NAPAD, iako može ostvarivati visok vojni učinak, istodobno nosi i povišen rizik kada je omjer snaga nepovoljan, zbog čega njezina udaljenost od anti-idealnog rješenja može biti manja nego što bi to sugerirao sam ponderirani zbroj kriterija.

4.2.6 Implementacija metode VIKOR

VIKOR metoda alternative rangira prema kompromisnom pokazatelju *Q*, koji se određuje kombiniranjem dvaju pokazatelja: ukupnog odstupanja alternative od idealnog rješenja po svim kriterijima (*S*) te najvećeg pojedinačnog odstupanja po jednom kriteriju (*R*). Matematički model metode, uključujući izračun pokazatelja *S, R* i *Q* te uvjeta prihvatljivosti *C1* i *C2*, detaljno je opisan u poglavlju 3.3, stoga je u nastavku prikazana isključivo njezina programska implementacija.

Funkcija vikor() (kod 4-8 i kod 4-9) za razliku od saw() i topsis() ne koristi zajedničke funkcije za normalizaciju matrice, već izravno određuje idealnu i anti-idealnu vrijednost svakog kriterija te za svaku izvedivu alternativu računa ponderirani jaz u odnosu na idealno rješenje. Zbroj tih jazova po svim kriterijima predstavlja pokazatelj *S*, dok najveći pojedinačni jaz predstavlja pokazatelj *R*. Kriterij kod kojeg se idealna i anti-idealna vrijednost podudaraju, odnosno koji ne razlikuje alternative, ne pridonosi izračunu.

Pokazatelji *S* i *R* potom se normaliziraju u odnosu na raspon ostvarenih vrijednosti te se kombiniraju u konačni pokazatelj *Q* prema parametru *v*, koji određuje relativnu težinu grupne koristi u odnosu na pojedinačno žaljenje. U implementaciji je taj parametar dostupan kao konfiguracijska vrijednost --vikor_v te je njegova zadana vrijednost 0,5, čime se grupna korist i pojedinačno žaljenje uzimaju u obzir ravnopravno. Manja vrijednost *Q* pritom označava povoljniju alternativu.

Nakon rangiranja prema pokazatelju *Q* provjeravaju se uvjeti prihvatljivosti. Uvjet *C1* provjerava postoji li dovoljna prednost prvorangirane alternative u odnosu na drugorangiranu, pri čemu granična vrijednost ovisi o broju izvedivih alternativa. Uvjet *C2* provjerava je li prvorangirana alternativa ujedno i najbolje rangirana prema barem jednom od pojedinačnih pokazatelja *S* ili *R*. Ukoliko jedan od uvjeta nije zadovoljen, umjesto jedinstvene pobjedničke alternative implementacija određuje kompromisni skup koji uz najbolje rangiranu alternativu uključuje i one alternative čija se vrijednost *Q* od nje ne razlikuje dovoljno da bi bile jednoznačno lošije.

```python
def vikor(matrix, weights, types, feasible, v=0.5, **kwargs):

    sub = submatrix(matrix, feasible)
    cols = len(weights)
    count = len(feasible)
    best = []
    worst = []
    for j in range(cols):
        column = [row[j] for row in sub]
        if types[j] > 0:
            best.append(max(column))
            worst.append(min(column))
        else:
            best.append(min(column))
            worst.append(max(column))

    s_values = {}
    r_values = {}

    for k, i in enumerate(feasible):
        terms = []
        for j in range(cols):
            span = best[j] - worst[j]
            gap = 0.0 if abs(span) <= 1e-12 else (best[j] - sub[k][j]) / span
            terms.append(weights[j] * gap)

        s_values[i] = sum(terms)
        r_values[i] = max(terms)

    s_best, s_worst = min(s_values.values()), max(s_values.values())
    r_best, r_worst = min(r_values.values()), max(r_values.values())
    s_span = s_worst - s_best
    r_span = r_worst - r_best

    q_values = {}
    for i in feasible:
        s_part = 0.0 if s_span <= 1e-12 else (s_values[i] - s_best) / s_span
        r_part = 0.0 if r_span <= 1e-12 else (r_values[i] - r_best) / r_span
        q_values[i] = v * s_part + (1.0 - v) * r_part

    result = MethodResult(q_values, higher_better=False)
    ranking = result.ranking
    first = ranking[0]
    second = ranking[1] if count > 1 else None
    threshold = 1.0 / (count - 1) if count > 1 else 0.0
```

Kod 4-8 Implementacija metode VIKOR (I. dio)

```
    c1 = True if second is None else (
        q_values[second] - q_values[first] >= threshold)
    best_s = min(s_values, key=lambda i: (s_values[i], i))
    best_r = min(r_values, key=lambda i: (r_values[i], i))
    c2 = first in (best_s, best_r)

    if not c1:
        compromise = [first]
        for candidate in ranking[1:]:
            if q_values[candidate] - q_values[first] < threshold:
                compromise.append(candidate)
            else:
                break
    elif not c2:
        compromise = [first, second] if second is not None else [first]
    else:
        compromise = [first]

    result.meta = {
        "S": s_values,
        "R": r_values,
        "c1": c1,
        "c2": c2,
        "compromise": compromise,
        "v": v,
    }

    return result


METHODS = {
    "saw": saw,
    "topsis": topsis,
    "vikor": vikor,
}

DEFAULT_SCHEME = {
    "saw": "linear",
    "topsis": "vector",
    "vikor": "linear",
}
```

Kod 4-9 Implementacija metode VIKOR (II. dio)

Ovime VIKOR, za razliku od metoda SAW i TOPSIS koje uvijek vraćaju jednoznačno rangiranje, ne mora predložiti jedinstvenu najbolju alternativu. Ta se osobina u razvijenom agentu prati kroz brojač koliko je puta uvjet *C1* zadovoljen, koliko puta je zadovoljen uvjet *C2* te kolika je prosječna veličina kompromisnog skupa tijekom izvođenja, a rezultati se ispisuju uz ostale mjere po završetku simulacije. Time se teorijska svojstva metode, opisana u poglavlju 3.3, mogu promatrati i kao izmjerene veličine tijekom stvarnog izvođenja agenta, što se dodatno razmatra u poglavlju 4.4.

4.3 Eksperimentalna metodologija

Nakon definiranja eksperimentalnog okruženja i implementacije MCDM metoda potrebno je definirati način provedbe eksperimenata i obrade dobivenih podataka. Eksperimenti su postavljeni tako da se različite MCDM metode mogu ispitivati pod jednakim uvjetima, dok se njihovi rezultati naknadno analiziraju na temelju podataka prikupljenih tijekom simulacije.

4.3.1 Eksperimentalni uvjeti

Eksperimenti se provode korištenjem prethodno opisanog simulacijskog okruženja i razvijenog agenta. Za pojedino izvođenje odabire se MCDM metoda pomoću parametra --mcdm, dok se ostali parametri simulacije mogu zadati putem naredbenog retka. Na taj način moguće je promatrati utjecaj odabrane metode na ponašanje agenta uz zadržavanje ostalih uvjeta eksperimenta.

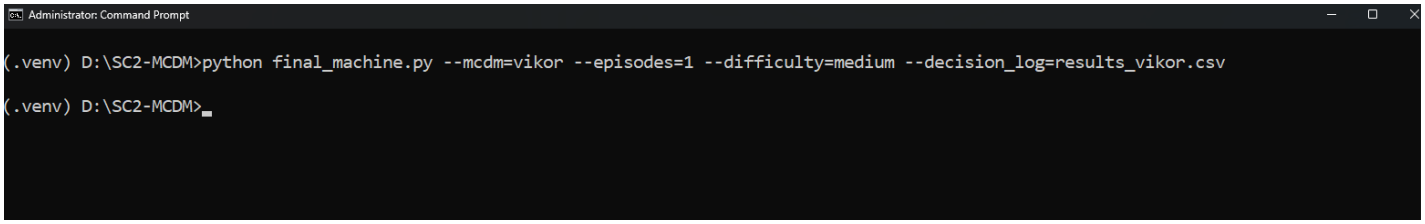
Za međusobnu usporedbu metoda potrebno je zadržati jednake uvjete izvođenja. To uključuje korištenu kartu, rasu agenta i protivnika, razinu težine računalno upravljanog protivnika, broj epizoda te, kada se koristi, vrijednost slučajnog sjemena. Promjenom samo odabrane MCDM metode omogućuje se da uočene razlike u donošenju odluka budu povezane s načinom rangiranja alternativa, a ne s promjenom osnovnih uvjeta simulacije.

U eksperimentima se za svaku MCDM metodu može koristiti zaseban zapis rezultata. Primjer pokretanja eksperimenta sa SAW metodom je:

- python final_machine.py --mcdm=saw --episodes 10 --difficulty=medium --decision_log results_saw.csv

Za TOPSIS i VIKOR mijenja se vrijednost argumenta --mcdm, dok ostali parametri mogu ostati jednaki:

- python final_machine.py --mcdm=topsis --episodes=10 --difficulty=medium --decision_log=results_topsis.csv
- python final_machine.py --mcdm=vikor --episodes=10 --difficulty=medium --decision_log=results_vikor.csv



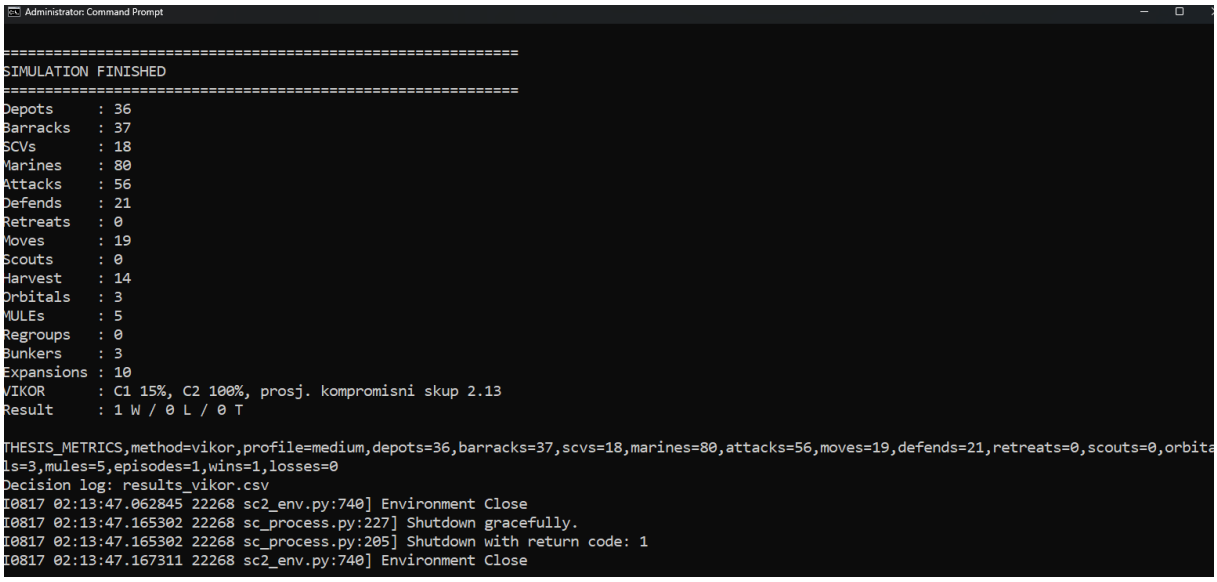
Slika 4-4 Primjer pokretanja jedne naredbe u naredbenom retku

4.3.2 Provedba eksperimenata

Za svako izvođenje agent započinje simulaciju u početnom stanju definirane karte te tijekom trajanja epizode kontinuirano opaža stanje igre i donosi odluke. Odabrana MCDM metoda u svakom koraku obrađuje trenutno stanje i određuje prioritet među izvedivim alternativama.

Eksperimenti s različitim metodama provode se na jednak način. Za svaku metodu određuje se broj epizoda, a tijekom svake epizode bilježe se odluke agenta i stanje simulacije. Nakon završetka epizode prikupljaju se podaci potrebni za analizu njezina ishoda.

Takvim pristupom moguće je razlikovati dvije razine eksperimentalnog promatranja. Prva se odnosi na ponašanje MCDM modela tijekom simulacije, odnosno na način na koji se mijenja izbor alternativa (slika 4-8). Druga se odnosi na konačni ishod epizode, kojim se procjenjuje uspješnost cjelokupnog agenta (slika 4-5).



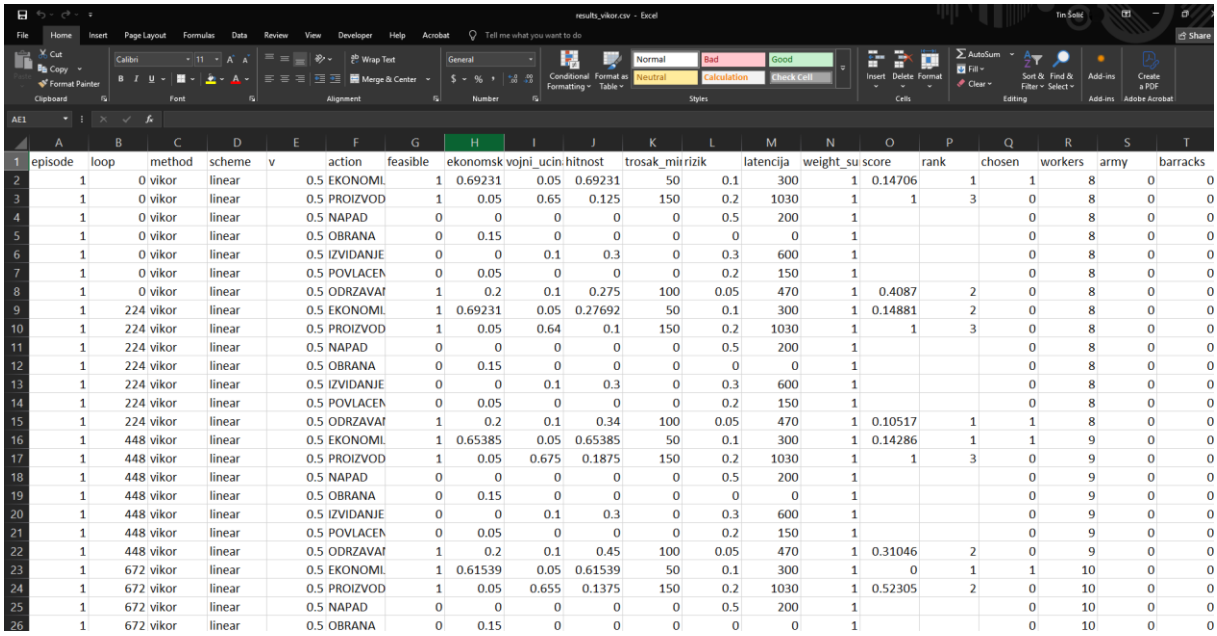
Slika 4-5 Završni ispis rezultata pojedine eksperimentalne epizode

4.3.1 Prikupljanje i zapis rezultata

Za detaljno praćenje procesa odlučivanja u implementaciji je predviđen zapisnik odluka (decision log). Zapisivanje se aktivira parametrom --decision_log, nakon čega se podaci pohranjuju u CSV datoteku. Na taj način rezultati pojedinačnih odluka mogu se analizirati nakon završetka simulacije, bez potrebe za ponovnim izvođenjem cijele igre.

Za svaku odluku zapisuje se podatak o epizodi i trenutku simulacije, korištenoj MCDM metodi, načinu normalizacije i parametru v metode VIKOR. Osim toga, zapis sadrži alternativu, njezinu izvedivost, vrijednosti svih kriterija, težine, dobiveni rezultat i rang te informaciju je li alternativa odabrana. U zapis se uključuju i podaci o trenutnom stanju igre, poput broja SCV jedinica, broja vojnih jedinica, broja vojarni, količine minerala, slobodnih resursa, broja protivničkih jedinica i broja prijetnji.

Nakon izvođenja rezultati se mogu učitati u program za daljnju obradu (slika 4-6). CSV format omogućuje filtriranje i grupiranje podataka prema različitim obilježjima, primjerice prema MCDM metodi, epizodi ili odabranoj alternativi. Time se iz istog skupa podataka mogu analizirati i pojedinačne odluke i ponašanje agenta kroz cijelu epizodu.



	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
1	episode	loop	method	scheme	v	action	feasible	ekonomsk	vojni_ucin	hitnost	trosak_mir	rizik	latencija	weight_su	score	rank	chosen	workers	army	barracks
2	1	0	vikor	linear	0.5	EKONOML	1	0.69231	0.05	0.69231	50	0.1	300	1	0.14706	1	1	8	0	0
3	1	0	vikor	linear	0.5	PROIZVOD	1	0.05	0.65	0.125	150	0.2	1030	1	1	3	0	8	0	0
4	1	0	vikor	linear	0.5	NAPAD	0	0	0	0	0	0.5	200	1			0	8	0	0
5	1	0	vikor	linear	0.5	OBRANA	0	0.15	0	0	0	0	0	1			0	8	0	0
6	1	0	vikor	linear	0.5	IZVIDANJE	0	0	0.1	0.3	0	0.3	600	1			0	8	0	0
7	1	0	vikor	linear	0.5	POVLACEN	0	0.05	0	0	0	0.2	150	1			0	8	0	0
8	1	0	vikor	linear	0.5	ODRZAVAI	1	0.2	0.1	0.275	100	0.05	470	1	0.4087	2	0	8	0	0
9	1	224	vikor	linear	0.5	EKONOML	1	0.69231	0.05	0.27692	50	0.1	300	1	0.14881	2	0	8	0	0
10	1	224	vikor	linear	0.5	PROIZVOD	1	0.05	0.64	0.1	150	0.2	1030	1	1	3	0	8	0	0
11	1	224	vikor	linear	0.5	NAPAD	0	0	0	0	0	0.5	200	1			0	8	0	0
12	1	224	vikor	linear	0.5	OBRANA	0	0.15	0	0	0	0	0	1			0	8	0	0
13	1	224	vikor	linear	0.5	IZVIDANJE	0	0	0.1	0.3	0	0.3	600	1			0	8	0	0
14	1	224	vikor	linear	0.5	POVLACEN	0	0.05	0	0	0	0.2	150	1			0	8	0	0
15	1	224	vikor	linear	0.5	ODRZAVAI	1	0.2	0.1	0.34	100	0.05	470	1	0.10517	1	1	8	0	0
16	1	448	vikor	linear	0.5	EKONOML	1	0.65385	0.05	0.65385	50	0.1	300	1	0.14286	1	1	9	0	0
17	1	448	vikor	linear	0.5	PROIZVOD	1	0.05	0.675	0.1875	150	0.2	1030	1	1	3	0	9	0	0
18	1	448	vikor	linear	0.5	NAPAD	0	0	0	0	0	0.5	200	1			0	9	0	0
19	1	448	vikor	linear	0.5	OBRANA	0	0.15	0	0	0	0	0	1			0	9	0	0
20	1	448	vikor	linear	0.5	IZVIDANJE	0	0	0.1	0.3	0	0.3	600	1			0	9	0	0
21	1	448	vikor	linear	0.5	POVLACEN	0	0.05	0	0	0	0.2	150	1			0	9	0	0
22	1	448	vikor	linear	0.5	ODRZAVAI	1	0.2	0.1	0.45	100	0.05	470	1	0.31046	2	0	9	0	0
23	1	672	vikor	linear	0.5	EKONOML	1	0.61539	0.05	0.61539	50	0.1	300	1	0	1	1	10	0	0
24	1	672	vikor	linear	0.5	PROIZVOD	1	0.05	0.655	0.1375	150	0.2	1030	1	0.52305	2	0	10	0	0
25	1	672	vikor	linear	0.5	NAPAD	0	0	0	0	0	0.5	200	1			0	10	0	0
26	1	672	vikor	linear	0.5	OBRANA	0	0.15	0	0	0	0	0	1			0	10	0	0

Slika 4-6 Generirani CSV

Posebna je prednost ovakvog načina zapisivanja što se ne sprema samo konačna odluka. Za svaku točku odlučivanja dostupne su i vrijednosti ostalih alternativa, zbog čega je moguće naknadno analizirati situacije u kojima su različite MCDM metode odabrale različite alternative.

4.3.2 Obrada rezultata i metrike evaluacije

Nakon završetka izvođenja CSV zapisi obrađuju se kako bi se omogućila analiza ponašanja agenta i usporedba rezultata različitih eksperimenata. Podaci se mogu grupirati prema korištenoj MCDM metodi, epizodi i alternativi, čime se dobiva pregled učestalosti pojedinih odluka i njihovih rezultata.

Za procjenu uspješnosti izvođenja koriste se podaci dostupni nakon završetka pojedine epizode, dok se za analizu samog procesa odlučivanja koriste podaci iz zapisnika odluka. Na taj se način odvojeno promatra kako agent odlučuje i koliko je uspješno njegovo ukupno ponašanje.

U analizi procesa odlučivanja mogu se promatrati:

- učestalost odabira pojedinih alternativa,
- promjena odabrane alternative tijekom epizode,
- rezultati pojedinih alternativa,
- rang alternativa,
- vrijednosti kriterija u trenutku donošenja odluke,
- razlike u odlukama između MCDM metoda.

Za analizu konačnog ishoda mogu se koristiti broj pobjeda i poraza, odnosno omjer uspješnih i neuspješnih epizoda, kao i ostale metrike koje programska implementacija zapisuje pri završetku simulacije.

Na temelju tako pripremljenih podataka u nastavku rada analiziraju se konkretni primjeri donošenja odluka te konačni rezultati eksperimentalnih izvođenja.

4.4 Rezultati eksperimentalnog istraživanja

U ovom poglavlju prikazani su rezultati dobiveni izvođenjem razvijenog agenta u definiranom simulacijskom okruženju. Analiza je usmjerena na ponašanje agenta tijekom simulacije, promjene odabranih alternativa te uspješnost pojedinih eksperimentalnih izvođenja. Posebna pažnja posvećena je razlikama u odlukama dobivenima primjenom različitih MCDM metoda.

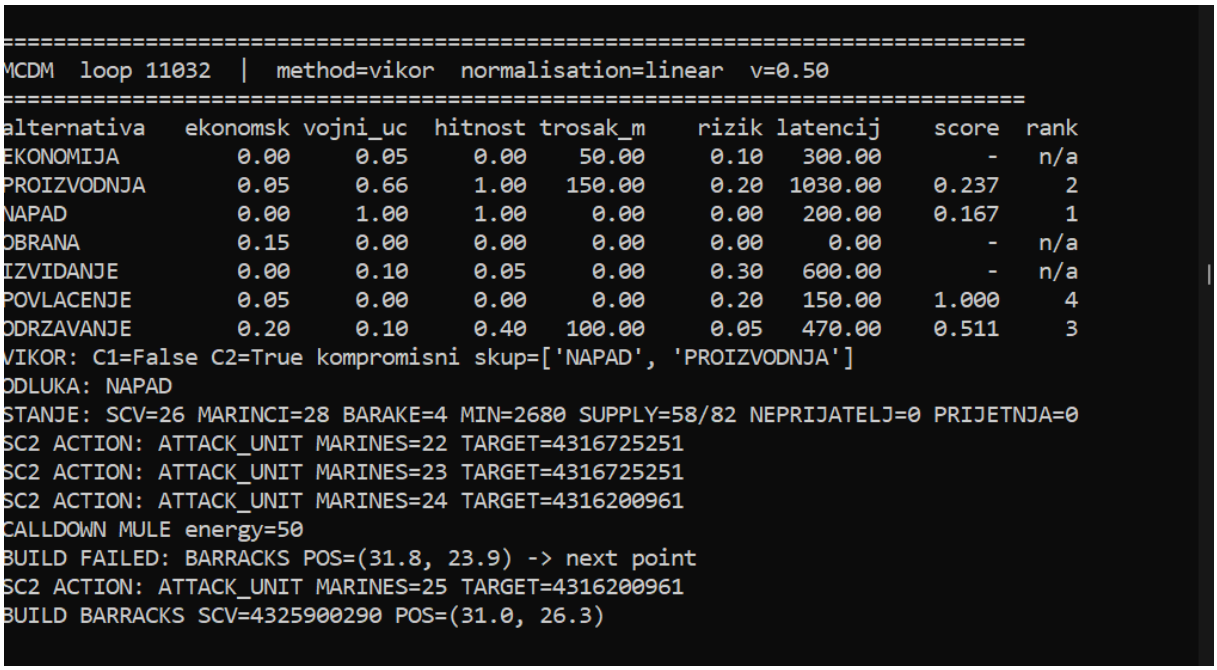
4.4.1 Ponašanje agenta tijekom simulacije

Tijekom izvođenja agent kontinuirano procjenjuje trenutno stanje simulacije i na temelju vrijednosti kriterija odabire jednu od izvedivih strateških alternativa. Budući da se stanje igre mijenja tijekom vremena, mijenjaju se i vrijednosti kriterija te posljedično prioriteti alternativa.

Za prikaz ponašanja agenta odabrana je reprezentativna epizoda u kojoj se može pratiti prijelaz između različitih faza djelovanja. U početnom dijelu simulacije agent prvenstveno usmjerava aktivnosti prema razvoju ekonomije i proizvodnih kapaciteta. Pojavom protivničke prijetnje mijenja se struktura kriterija, zbog čega veći prioritet mogu dobiti obrambene aktivnosti. Nakon povećanja vlastite vojne snage moguće je ponovno povećanje prioriteta napadačkih aktivnosti.



Slika 4-7 Vizualni prikaz simulacije



Slika 4-8 Prikaz ispisa u naredbenom retku

4.4.2 Dinamika MCDM odluka

Tijekom simulacije odabrana alternativa mijenja se ovisno o trenutnom stanju sustava. U svakom koraku agent ponovno procjenjuje dostupne alternative, pri čemu se vrijednosti kriterija prilagođavaju trenutačnom stanju vlastitih i protivničkih snaga. Na taj se način odluka ne donosi jednom za cijelu epizodu, već se ponovno određuje tijekom njezina izvođenja.

Na slici 4-8 prikazan je primjer odluke donesene metodom VIKOR. U promatranom trenutku agent raspolaže s 26 SCV jedinica, 28 Marinaca i četiri vojarne, uz 2680 minerala i slobodni kapacitet od 58/82. Istodobno nema registriranih protivničkih jedinica niti prijetnji unutar vlastite baze.

U takvom stanju najveću vrijednost vojnog učinka ostvaruje alternativa NAPAD, s vrijednošću 1,00, dok je vrijednost hitnosti također 1,00. Za alternativu PROIZVODNJA vojni učinak iznosi 0,66, dok je kod ostalih alternativa vojni učinak niži ili jednak nuli. VIKOR u ovom koraku određuje kompromisni skup koji sadrži alternative NAPAD i PROIZVODNJA, pri

čemu je NAPAD rangiran na prvom mjestu s rezultatom 0,167, a PROIZVODNJA na drugom mjestu s rezultatom 0,237.

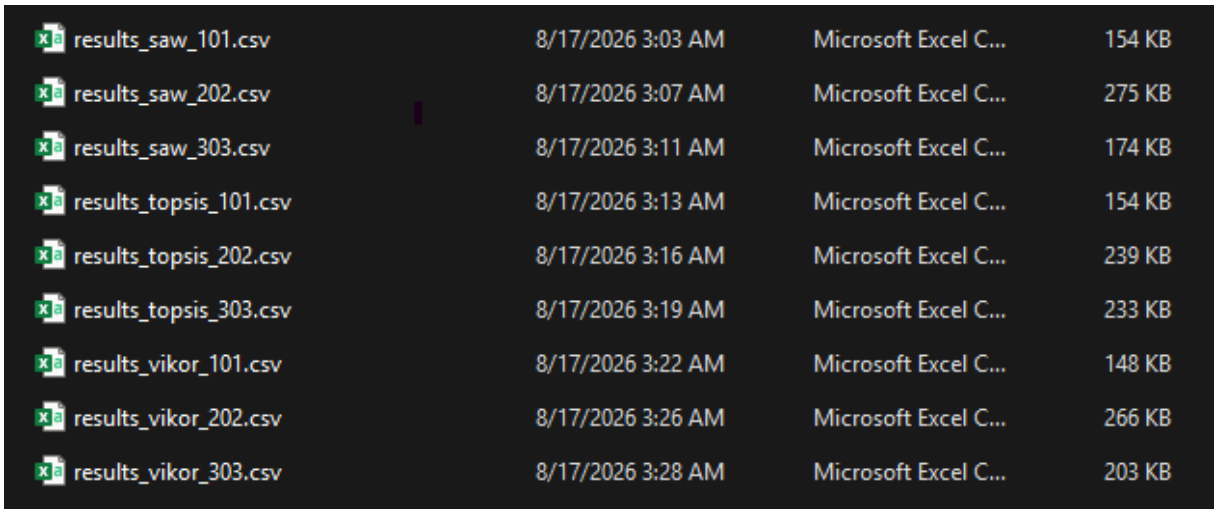
Konačno je odabrana alternativa NAPAD, nakon čega se odluka prosljeđuje izvršnom dijelu agenta. U naredbenom retku vidljivo je da agent zatim provodi akcije ATTACK_UNIT nad odabranim protivničkim ciljevima. U prikazanom trenutku odabrana odluka stoga nije ostala samo na razini MCDM rangiranja, već je izravno rezultirala konkretnom akcijom u simulacijskom okruženju.

Na taj se način može uočiti osnovna dinamika razvijenog agenta: promjena ulaznog stanja uzrokuje promjenu vrijednosti kriterija, promjenu rangiranja alternativa i, naposljetku, promjenu konkretne akcije agenta. Ovakav slijed predstavlja jednu od ključnih karakteristika primijenjenog pristupa, jer odluka nije unaprijed određena, već se prilagođava trenutnim uvjetima simulacije.

4.4.3 Rezultati izvođenja

Za procjenu uspješnosti razvijenog agenta provedena su eksperimentalna izvođenja u prethodno definiranom simulacijskom okruženju. U svim izvođenjima korištena je srednja razina težine protivničkog računalno upravljanog agenta (medium) te karta Simple64. Za svaku od implementiranih MCDM metoda — SAW, TOPSIS i VIKOR — provedena su tri eksperimentalna bloka po pet epizoda, pri čemu su za pojedine blokove korišteni različiti seedovi. Isti skup slučajnih seedova korišten je za sve tri metode kako bi se omogućila usporedivost rezultata. Ukupno je tako provedeno 15 epizoda po metodi, odnosno 45 epizoda za sve tri metode.

Za svaku epizodu bilježi se njezin konačni ishod, pri čemu se razlikuju pobjede, porazi i eventualno neriješeni ishodi. Rezultati pojedinih blokova zasebno se zapisuju u CSV datoteke (slika 4-9), čime se omogućuje naknadna obrada podataka i analiza ponašanja agenta. Osim konačnog ishoda epizode, iz zapisa odluka mogu se analizirati i promjene odabranih alternativa te vrijednosti kriterija tijekom simulacije.



Slika 4-9 Ispis CSV datoteka

Tablica 4-2 Raspodjela odabranih alternativa prema korištenoj MCDM metodi

Alternativa	SAW	TOPSIS	VIKOR
EKONOMIJA	197 (19,26 %)	153 (15,00 %)	154 (14,92 %)
PROIZVODNJA	279 (27,27 %)	383 (37,55 %)	349 (33,82 %)
NAPAD	344 (33,63 %)	360 (35,29 %)	227 (22,00 %)
OBRANA	196 (19,16 %)	122 (11,96 %)	284 (27,52 %)
IZVIĐANJE	0 (0,00 %)	1 (0,10 %)	1 (0,10 %)
POVLAČENJE	1 (0,10 %)	1 (0,10 %)	1 (0,10 %)
ODRŽAVANJE	6 (0,59 %)	0 (0,00 %)	16 (1,55 %)
Ukupno	1023	1020	1032

4.4.4 Usporedba MCDM metoda

Rezultati pokazuju da, iako sve tri metode koriste isti skup alternativa, kriterija i težina, njihov način obrade matrice odlučivanja dovodi do različite raspodjele strateških odluka. Razlike su posebno vidljive kod alternativa PROIZVODNJA, NAPAD i OBRANA, koje zajedno čine najveći dio svih donesenih odluka.

Kod metode SAW najzastupljenija je alternativa NAPAD, odabrana u 344 od ukupno 1023 odluke (33,63 %). PROIZVODNJA slijedi s 279 odabira (27,27 %), dok su EKONOMIJA i OBRANA gotovo jednako zastupljene, s 19,26 % odnosno 19,16 % odluka.

TOPSIS pokazuje nešto drugačiju raspodjelu. Najčešće je odabrana PROIZVODNJA, s 383 od ukupno 1020 odluka (37,55 %), dok je NAPAD vrlo blizu s 360 odabira (35,29 %). U odnosu na SAW, TOPSIS rjeđe odabire OBRANU, koja sudjeluje u 11,96 % odluka.

Kod VIKOR-a također je najzastupljenija PROIZVODNJA, s 349 od 1032 odluke (33,82 %), ali se istodobno uočava znatno veći udio OBRANE. Ona je odabrana u 284 slučaja, odnosno 27,52 % svih odluka. NAPAD je kod VIKOR-a zastupljen s 22,00 %, što je najmanji udio među tri metode.

Takva raspodjela ukazuje na različite obrasce ponašanja metoda. SAW pokazuje izraženiju sklonost prema napadačkim odlukama, TOPSIS prema proizvodnji uz gotovo jednaku zastupljenost napada, dok VIKOR pokazuje izraženiju sklonost prema obrambenim aktivnostima. Razlike su posebno vidljive u odnosu između NAPADA i OBRANE, gdje SAW i VIKOR pokazuju gotovo suprotne obrasce.

Važno je pritom naglasiti da se na temelju ove analize ne može zaključiti da je jedna metoda općenito bolja od druge. Prikazani rezultati opisuju ponašanje metoda u konkretno definiranom eksperimentalnom scenariju, pri čemu na konačni ishod utječu i postavljeni kriteriji, njihove težine, protivničko ponašanje te dinamika same simulacije.

Time je eksperimentalni dio pokazao da izbor MCDM metode ne utječe samo na numerički rang alternativa, već i na strateško ponašanje agenta tijekom simulacije. To predstavlja osnovu za raspravu o dobivenim rezultatima i njihovoj mogućoj primjeni izvan simulacijskog okruženja.

4.5 Rasprava

4.5.1 Analiza dobivenih rezultata

Provedeni eksperimenti pokazuju da izbor MCDM metode utječe na način na koji agent određuje strateški prioritet. Iako su kod svih metoda korišteni isti kriteriji, težine i skup alternativa, dobivena raspodjela odluka nije jednaka. To potvrđuje da razlika između metoda nije samo teorijska, već se izravno odražava na ponašanje agenta u simulaciji.

SAW je pokazao izraženiju sklonost prema alternativi NAPAD, dok TOPSIS veći udio odluka usmjerava prema PROIZVODNJI. VIKOR se posebno razlikuje po većem udjelu odluka OBRANA. Takvo ponašanje proizlazi iz različitog načina na koji metode vrednuju odnos između kriterija i položaj pojedine alternative u matrici odlučivanja.

Istodobno, nijedna metoda nije pokazala isključivu sklonost prema samo jednoj vrsti aktivnosti. Sve tri metode tijekom simulacije kombiniraju ekonomske, proizvodne, napadačke i obrambene odluke, što je važno za dinamički karakter problema. Agent se stoga ne ponaša prema unaprijed određenom slijedu aktivnosti, već se odluka mijenja zajedno s promjenom stanja simulacije.

Dobiveni rezultati stoga pokazuju da odabir MCDM metode predstavlja jedan od čimbenika koji određuju ponašanje sustava, dok konačna kvaliteta odluke ovisi i o načinu definiranja kriterija, njihovih težina i modela kojim se stanje sustava pretvara u vrijednosti kriterija.

4.5.2 Ograničenja eksperimentalnog pristupa

Eksperiment je proveden u kontroliranom okruženju SC2, zbog čega se dobiveni rezultati ne mogu izravno prenijeti na stvarne krizne situacije. Simulacija omogućuje ispitivanje dinamike odlučivanja, ali ne predstavlja fizički model požara, evakuacije ili djelovanja interventnih službi.

Dodatno ograničenje predstavlja činjenica da su kriteriji, njihove težine i dostupne alternative definirani za potrebe ovog eksperimenta. Njihova prikladnost za stvarni krizni sustav zahtijevala bi validaciju na stvarnim podacima i uz sudjelovanje stručnjaka iz područja kriznog upravljanja.

Zbog navedenog, rezultate treba promatrati kao provjeru funkcionalnosti i ponašanja predloženog pristupa, a ne kao konačnu procjenu njegove primjenjivosti u stvarnim kriznim situacijama.

4.5.3 Mogućnost primjene na krizno upravljanje

U scenariju šumskog požara, primjerice, trenutnom stanju sustava mogu odgovarati podaci o položaju i širenju požara, raspoloživim interventnim snagama, prohodnosti terena, ugroženosti stanovništva i dostupnim resursima.

Postojeće strateške alternative tada bi se mogle zamijeniti odlukama poput gašenja požara, zaštite kritične infrastrukture, evakuacije, izviđanja, preraspodjele snaga ili povlačenja iz ugroženog područja. Na taj način struktura korištena u eksperimentu može poslužiti kao osnova za razvoj specijaliziranog sustava potpore odlučivanju u kriznom upravljanju.

U tom smislu vrijednost provedenog eksperimenta nije u tome da SC2 predstavlja stvarni požar, već u tome što omogućuje kontrolirano ispitivanje kako se višekriterijsko odlučivanje ponaša u dinamičkom okruženju u kojem se stanje sustava i prioriteti odluka kontinuirano mijenjaju.

4.5.4 Smjerovi daljnjeg razvoja sustava

Rezultati provedenog eksperimenta otvaraju pitanje koje nadilazi samu usporedbu primijenjenih MCDM metoda: može li se ovakav model odlučivanja razviti u sustav koji bi u stvarnom vremenu pružao potporu donošenju odluka u sigurnosno kritičnim situacijama? U kriznom upravljanju vrijednost takvog sustava ne bi bila samo u sposobnosti pronalaženja najbolje alternative, nego u sposobnosti da pravodobno prepozna promjenu situacije, procijeni njezine posljedice i prilagodi preporučenu odluku prije nego što prethodna odluka postane neprimjenjiva.

Takav sustav mogao bi se koncipirati kao višeslojna arhitektura u kojoj MCDM ne predstavlja samostalni algoritam za donošenje odluke, već središnji sloj za evaluaciju i rangiranje mogućih postupaka. Prvi sloj činio bi sustav za prikupljanje podataka iz senzorskih mreža, geografskih informacijskih sustava, satelitskih snimki, bespilotnih letjelica i drugih dostupnih izvora. Drugi sloj bio bi zadužen za obradu, provjeru i procjenu kvalitete pristiglih podataka. Na temelju tako obrađenih podataka formirale bi se vrijednosti kriterija i njihova važnost, nakon čega bi MCDM

sloj rangirao raspoložive alternative. Konačna odluka pritom ne bi morala biti potpuno automatizirana, već bi sustav mogao djelovati kao inteligentna potpora stručnjaku koji zadržava odgovornost za donošenje odluke.

Poseban izazov predstavlja činjenica da bi se takav sustav u stvarnoj primjeni nalazio u sigurnosno kritičnom okruženju. Pogreška u procjeni kriterija, nepravodobni podaci ili pogrešno određene težine kriterija mogu dovesti do preporuke koja je matematički konzistentna, ali operativno neprihvatljiva. Stoga bi budući razvoj morao uključivati mehanizme provjere pouzdanosti ulaznih podataka, analizu osjetljivosti rezultata, detekciju anomalija i mogućnost intervencije stručne osobe prije provedbe kritične odluke.

Posebno zanimljiv smjer daljnjeg razvoja predstavlja dinamičko određivanje težina kriterija. U stvarnoj kriznoj situaciji važnost pojedinog kriterija ne mora biti konstantna tijekom cijelog događaja. Primjerice, u početnoj fazi šumskog požara raspoloživost resursa i mogućnost ograničavanja širenja požara mogu imati najveću važnost, dok nakon približavanja požara naseljenom području prioritet može biti preusmjeren prema sigurnosti stanovništva i brzini evakuacije. Sustav koji bi mogao automatski prilagođavati težine kriterija promjeni razine prijetnje predstavljao bi značajan korak prema stvarnom dinamičkom sustavu potpore odlučivanju.

5 ZAKLJUČAK

Krizno upravljanje predstavlja jedno od područja u kojima kvaliteta donošenja odluka može izravno utjecati na sigurnost ljudi, infrastrukture i okoliša. Za razliku od stabilnih uvjeta u kojima donositelj odluke može raspolagati dovoljnim vremenom za analizu različitih mogućnosti, krizne situacije karakteriziraju vremenski pritisak, nepotpune informacije, promjenjivi uvjeti i simultano postojanje više međusobno povezanih ciljeva. Upravo u takvom okruženju postaje vidljivo ograničenje pristupa prema kojem se odluka može temeljiti na samo jednom kriteriju ili unaprijed definiranom scenariju. Uvod rada polazi upravo od tog problema, odnosno od potrebe da se sigurnosno relevantne odluke promatraju u vidu dinamičkog procesa u kojem se prioriteti moraju prilagođavati razvoju događaja.

U radu je stoga analizirana primjena metoda višekriterijskog odlučivanja kao mogućeg mehanizma za strukturiranje takvog procesa. Teorijskim pregledom metoda AHP, VIKOR i TOPSIS prikazane su njihove osnovne značajke, načini određivanja važnosti kriterija, postupci rangiranja alternativa te mogućnosti i ograničenja njihove primjene u području kriznog upravljanja. Posebna vrijednost rada ostvarena je eksperimentalnim dijelom, u kojem metode nisu promatrane samo kroz statičan problem konačnog rangiranja alternativa, već su uključene u dinamički proces odlučivanja unutar simulacijskog okruženja StarCraft II Learning Environment.

Eksperiment je pokazao da izbor MCDM metode nije neutralan element sustava. Iako su metode primijenjene nad istim skupom kriterija i nad istim promjenjivim stanjem simulacije, njihovi rezultati mogu dovesti do različitih prioriteta i različitog ponašanja agenta. Istodobno, niti jedna metoda nije pokazala potpuno izolirano ponašanje prema samo jednoj vrsti aktivnosti, već su se odluke mijenjale ovisno o stanju sustava. Time je potvrđeno da MCDM metoda predstavlja važan, ali ne i jedini čimbenik konačne odluke. Na njezin rezultat jednako značajno utječu izbor kriterija, njihove težine te način na koji se stvarno stanje sustava pretvara u kriterijske vrijednosti.

Jedan od važnijih zaključaka rada proizlazi upravo iz činjenice da korišteno simulacijsko okruženje nije stvarni model kriznog događaja. SC2LE omogućio je kontrolirano ispitivanje ponašanja MCDM metoda u sustavu u kojem se stanje, resursi i raspoložive mogućnosti kontinuirano mijenjaju, ali dobiveni rezultati ne mogu se izravno interpretirati kao dokaz

primjenjivosti sustava u stvarnom požaru, evakuaciji ili djelovanju interventnih službi. Za takav bi korak bila potrebna validacija modela na stvarnim podacima, definiranje kriterija u suradnji sa stručnjacima te sustavno ispitivanje pouzdanosti i robusnosti rezultata.

Međutim, upravo to ograničenje ujedno definira i najvažniji smjer daljnjeg razvoja. Eksperimentalni model moguće je promatrati kao pojednostavljenu jezgru budućeg sustava potpore odlučivanju u kojem bi se podaci o stvarnom stanju kriznog događaja kontinuirano prikupljali iz senzorskih mreža, geografskih informacijskih sustava, satelitskih snimaka, bespilotnih letjelica i drugih izvora. Na temelju tih podataka sustav bi mogao procjenjivati stanje rizika, formirati vrijednosti kriterija, rangirati moguće postupke i ponovno izračunavati prioritete nakon svake značajne promjene situacije. Takav pristup bio bi u skladu sa suvremenim konceptom kriznog upravljanja koji naglasak više ne stavlja samo na reakciju nakon nastanka događaja, nego i na kontinuirano praćenje, procjenu rizika i pravodobno prepoznavanje promjena.

Pri tome se kao posebno važan budući problem nameće pouzdanost automatiziranog odlučivanja u sigurnosno kritičnim uvjetima. Sustav koji donosi matematički konzistentnu odluku ne mora nužno donijeti i sigurnosno ispravnu odluku ako su ulazni podaci nepotpuni, zastarjeli ili pogrešni. Zbog toga budući razvoj ne bi trebao težiti potpunom uklanjanju čovjeka iz procesa odlučivanja, već izgradnji inteligentnog sustava potpore u kojem umjetna inteligencija i MCDM metode omogućuju bržu obradu informacija i kvalitetnije vrednovanje alternativa, dok konačna odgovornost za kritične odluke ostaje pod nadzorom stručnog donositelja odluke.

Posebno obećavajući smjer predstavlja dinamičko određivanje težina kriterija. U stvarnoj kriznoj situaciji važnost pojedinog kriterija može se mijenjati zajedno s razinom prijetnje. Kod šumskog požara, primjerice, početni naglasak može biti na ograničavanju širenja požara i optimalnom rasporedu interventnih resursa, dok približavanje požara naseljenom području može potpuno promijeniti prioritete prema sigurnosti stanovništva i brzini evakuacije. Razvoj modela koji bi takve promjene mogao prepoznati i automatski odraziti u procesu višekriterijskog odlučivanja predstavlja prirodan nastavak istraživanja provedenog u ovom radu.

Konačno, doprinos ovog rada nije u tome da jedna od promatranih MCDM metoda predstavlja univerzalno najbolje rješenje za krizno upravljanje. Rezultati upravo suprotno pokazuju da izbor metode mora biti povezan s prirodom problema, kriterijima, njihovim težinama i karakteristikama sustava u kojem se odluka donosi. Vrijednost MCDM pristupa nalazi se u mogućnosti da složeni problem pretvori u strukturiran, transparentan i ponovljiv proces odlučivanja, dok njegova stvarna uporabna vrijednost ovisi o kvaliteti podataka i modela na kojem se odluka temelji.

U tom smislu, ovaj rad predstavlja korak od statičkog rangiranja alternativa prema dinamičkom sustavu potpore odlučivanju. Sljedeći korak nije jednostavno povećanje broja alternativa ili kriterija, nego prijelaz prema sustavu koji bi mogao razumjeti promjenu rizika, prilagođavati prioritete, procjenjivati pouzdanost vlastitih preporuka i pravodobno podržati čovjeka u donošenju odluke kada za pogrešku više nema vremena.

LITERATURA

[1] D. P. Coppola, *Introduction to international disaster management*, 3d edition. Amsterdam: Elsevier/Butterworth-Hein, 2015.

[2] E. B. K. Lee, D. L. Van Bossuyt, and J. F. Bickford, "Digital Twin-Enabled Decision Support in Mission Engineering and Route Planning," *Systems*, vol. 9, no. 4, p. 82, Nov. 2021, doi: 10.3390/systems9040082.

[3] G.-H. Tzeng and J.-J. Huang, *Multiple Attribute Decision Making*, 0 ed. Chapman and Hall/CRC, 2011. doi: 10.1201/b11032.

[4] E. Triantaphyllou, "Multi-Criteria Decision Making Methods," in *Multi-criteria Decision Making Methods: A Comparative Study*, vol. 44, in Applied Optimization, vol. 44. , Boston, MA: Springer US, 2000, pp. 5–21. doi: 10.1007/978-1-4757-3157-6_2.

[5] T. L. Saaty and L. G. Vargas, *Models, methods, concepts & applications of the analytic hierarchy process*, 2nd ed. in International series in operations research & management science, no. v. 175. New York: Springer, 2012.

[6] C.-L. Hwang and K. Yoon, *Multiple Attribute Decision Making: Methods and Applications A State-of-the-Art Survey*. in Lecture Notes in Economics and Mathematical Systems, no. 186. Berlin Heidelberg: Springer, 1981. doi: 10.1007/978-3-642-48318-9.

[7] S. Opricovic and G.-H. Tzeng, "Compromise solution by MCDM methods: A comparative analysis of VIKOR and TOPSIS," *Eur. J. Oper. Res.*, vol. 156, no. 2, pp. 445–455, Jul. 2004, doi: 10.1016/S0377-2217(03)00020-1.

[8] O. Vinyals *et al.*, "StarCraft II: A New Challenge for Reinforcement Learning," Aug. 16, 2017, *arXiv*: arXiv:1708.04782. doi: 10.48550/arXiv.1708.04782.

[9] "Google DeepMind," Google DeepMind. Accessed: Aug. 31, 2026. [Online]. Available: https://deepmind.google/

[10] "About - Blizzard Entertainment." Accessed: Aug. 31, 2026. [Online]. Available: https://blizzard.com

[11] R. Parasuraman and V. Riley, “Humans and Automation: Use, Misuse, Disuse, Abuse,” *Hum. Factors J. Hum. Factors Ergon. Soc.*, vol. 39, no. 2, pp. 230–253, Jun. 1997, doi: 10.1518/001872097778543886.

[12] N. A. Smuha, “Regulation 2024/1689 of the Eur. Parl. & Council of June 13, 2024 (EU Artificial Intelligence Act),” *Int. Leg. Mater.*, vol. 64, no. 5, pp. 1234–1381, Oct. 2025, doi: 10.1017/ilm.2024.46.

[13] D. Alexander, *Principles of emergency planing and management*. London: Terra, 2002.

[14] S. J. Russell and P. Norvig, *Artificial intelligence: a modern approach*, Fourth edition, Global edition. in Prentice Hall series in artificial intelligence. Boston: Pearson, 2022.

[15] M. Blahova, “Crisis Management and Its Information Software Security,” in *2022 26th International Conference on Circuits, Systems, Communications and Computers (CSCC)*, Crete, Greece: IEEE, Jul. 2022, pp. 134–138. doi: 10.1109/CSCC55931.2022.00032.

[16] H. L. Tay, R. Banomyong, P. Varadejsatitwong, and P. Julagasigorn, “Mitigating Risks in the Disaster Management Cycle,” *Adv. Civ. Eng.*, vol. 2022, no. 1, p. 7454760, Jan. 2022, doi: 10.1155/2022/7454760.

[17] T. L. Saaty, *Multicriteria decision making: the analytic hierarchy process ; planning, priority setting, resource allocation*, 2. ed., with New material added. in The analytic hierarchy process series, no. 1. New York: McGraw-Hill, 1988.

[18] L. Y. Chen and T.-C. Wang, “Optimizing partners’ choice in IS/IT outsourcing projects: The strategic decision of fuzzy VIKOR,” *Int. J. Prod. Econ.*, vol. 120, no. 1, pp. 233–242, Jul. 2009, doi: 10.1016/j.ijpe.2008.07.022.

[19] C.-H. Chang, J.-J. Lin, J.-H. Lin, and M.-C. Chiang, “Domestic open-end equity mutual fund performance evaluation using extended TOPSIS method with different distance approaches,” *Expert Syst. Appl.*, vol. 37, no. 6, pp. 4642–4649, Jun. 2010, doi: 10.1016/j.eswa.2009.12.044.

[20] “StarCraft II.” Accessed: Aug. 31, 2026. [Online]. Available: https://starcraft2.blizzard.com/en-us/

[21] “Alphabet Investor Relations - Home.” Accessed: Aug. 31, 2026. [Online]. Available: https://abc.xyz/

[22] H. Taherdoost, “Analysis of Simple Additive Weighting Method (SAW) as a MultiAttribute Decision-Making Technique: A Step-by-Step Guide,” *J. Manag. Sci. Eng. Res.*, vol. 6, no. 1, pp. 21–24, Feb. 2023, doi: 10.30564/jmser.v6i1.5400.

PRILOZI

Kazalo slika, tablica i kodova

Kazalo slika

Slika 3-1 Opći primjer hijerarhijske strukture AHP metode 10
Slika 3-2 Matrica parnih usporedbu 13
Slika 3-3 Matrica primitivnog primjera odabira optimalne evakuacijske rute tijekom požara 14
Slika 3-4 Normalizirana matrica 14
Slika 3-5 Vektor prioriteta 15
Slika 3-6 Matrica odlučivanja VIKOR metode 20
Slika 3-7 Matrica odlučivanja TOPSIS metode 30
Slika 3-8 Normalizirana matrica 32
Slika 3-9 Ponderirana normalizirana matrica 34
Slika 4-1 Prograrmski direktorij 45
Slika 4-2 Dijagram toka eksperimentalnog postupka i procesa odlučivanja agenta 47
Slika 4-3 Direktorij s kartama SC2 48
Slika 4-4 Primjer pokretanja jedne naredbe u naredbenom retku 70
Slika 4-5 Završni ispis rezultata pojedine eksperimentalne epizode 71
Slika 4-6 Generirani CSV 72
Slika 4-7 Vizualni prikaz simulacije 74
Slika 4-8 Prikaz ispisa u naredbenom retku 75
Slika 4-9 Ispis CSV datoteka 77

Kazalo tablica

Tablica 3-1 Saatyjeva skala 12
Tablica 3-2 Unaprijed definirane vrijednosti slučajnog indeksa RI [5] 16
Tablica 3-3 Primjer matrice odlučivanja za VIKOR metodu 21
Tablica 3-4 Idealne i anti-idealne vrijednosti kriterija 23
Tablica 3-5 Normalizirana matrica odlučivanja 24
Tablica 3-6 Primjer matrice odlučivanja za TOPSIS metodu 31

Tablica 3-7 Normalizirana matrica odlučivanja 33
Tablica 3-8 Ponderirana normalizirana matrica odlučivanja 35
Tablica 3-9 Tablica idealnih i anti-idealnih vrijednosti 36
Tablica 3-10 Udaljenosti alternativa od idealnog i anti-idealnog rješenja 40
Tablica 4-1 Parametri konfiguracije simulacijskog scenarija 49
Tablica 4-2 Raspodjela odabranih alternativa prema korištenoj MCDM metodi 77

Kazalo kodova

Kod 4-1 Definicija konfiguracijskih parametara u programskoj implementaciji 51
Kod 4-2 Implementacija TOPSIS metode 53
Kod 4-3 Definicija kriterija, njihovih težina i alternativa u programskoj implementaciji 57
Kod 4-4 Izračun ulaznih vrijednosti za formiranje matrice odlučivanja 59
Kod 4-5 Formiranje vrijednosti kriterija za pojedine alternative 60
Kod 4-6 Funkcija available 61
Kod 4-7 Implementacija SAW metode 64
Kod 4-8 Implementacija metode VIKOR (I. dio) 67
Kod 4-9 Implementacija metode VIKOR (II. dio) 68

Popis oznaka i kratica

A^*	idealno rješenje (TOPSIS)
A^-	anti-idealno rješenje (TOPSIS)
a_{ij}	element matrice parnih usporedbi kriterija *i* i *j* (AHP)
AHP	analitički hijerarhijski proces (eng. *Analytic Hierarchy Process*)
API	programsko sučelje za aplikacije (eng. *Application Programming Interface*)
CI	indeks konzistentnosti (eng. *Consistency Index*, AHP)
C_j^*	koeficijent relativne bliskosti j-te alternative (TOPSIS)
CMD	naredbeni redak (eng. *Command Prompt*)
CR	omjer konzistentnosti (eng. *Consistency Ratio*, AHP)
CSV	vrijednosti odvojene zarezom (eng. *Comma-Separated Values*)
d_{ij}	normalizirano odstupanje i-tog kriterija za j-tu alternativu (VIKOR)
D_j^*	udaljenost j-te alternative od idealnog rješenja (TOPSIS)
D_j^-	udaljenost j-te alternative od anti-idealnog rješenja (TOPSIS)
$d_p(A, B)$	udaljenost između alternativa A i B prema Minkowski metrici s parametrom p (TOPSIS)
eng.	engleski (oznaka uz izvorne nazive stranih pojmova)
f_{ij}	vrijednost i-tog kriterija za j-tu alternativu (VIKOR, matrica odlučivanja)
f_i^*	idealna vrijednost i-tog kriterija (VIKOR)
f_i^-	anti-idealna vrijednost i-tog kriterija (VIKOR)

GIS	geografski informacijski sustav (eng. *Geographic Information System*)
i	indeks kriterija
j	indeks alternative
m	ukupan broj alternativa
MCDM	višekriterijsko odlučivanje (eng. *Multi-Criteria Decision Making*)
n	ukupan broj kriterija
p	parametar Minkowski metrike udaljenosti (TOPSIS)
PySC2	Python programsko sučelje za povezivanje s igrom StarCraft II
Q_j	kompromisni indeks j-te alternative (VIKOR)
r_{ij}	normalizirana vrijednost i-tog kriterija za j-tu alternativu (TOPSIS)
R^*	najmanja vrijednost pokazatelja R (VIKOR)
R^-	najveća vrijednost pokazatelja R (VIKOR)
R_j	najveće pojedinačno ponderirano odstupanje j-te alternative (VIKOR)
RI	slučajni indeks (eng. *Random Index*, AHP)
RL	podržano učenje (eng. *Reinforcement Learning*)
SAW	jednostavna aditivna metoda težina (eng. *Simple Additive Weighting*)
SC2	StarCraft II
SC2LE	StarCraft II Learning Environment
SCV	građevinsko vozilo rase Terran (eng. *Space Construction Vehicle*)
S_j	ukupna udaljenost j-te alternative od idealnog rješenja (VIKOR)

S^*	najmanja vrijednost pokazatelja S (VIKOR)
S^-	najveća vrijednost pokazatelja S (VIKOR)
TOPSIS	tehnika rangiranja prema sličnosti s idealnim rješenjem (eng. *Technique for Order of Preference by Similarity to Ideal Solution*)
v	težinski parametar VIKOR metode (odnos strategija)
v_{ij}	ponderirana normalizirana vrijednost i-tog kriterija za j-tu alternativu (TOPSIS)
v_i^*	idealna ponderirana vrijednost i-tog kriterija (TOPSIS)
v_i^-	anti-idealna ponderirana vrijednost i-tog kriterija (TOPSIS)
VIKOR	višekriterijska optimizacija i kompromisno rješenje (*VIšekriterijumsko Kompromisno Rangiranje*)
.venv	virtualno Python okruženje
w_i	težina i-tog kriterija
x_i, y_i	vrijednosti i-te dimenzije (kriterija) alternativa A i B (TOPSIS, formula udaljenosti)
λ_{max}	najveća vlastita vrijednost matrice parnih usporedbi (AHP)

SAŽETAK I KLJUČNE RIJEČI

Sažetak

Kada nastupi kriza – potres, poplava, požar ili bilo koji drugi događaj koji ugrožava veći broj ljudi – odluka o evakuaciji mora se donijeti u roku od nekoliko minuta, na temelju informacija koje su gotovo uvijek nepotpune, proturječne ili zastarjele. Problem pritom nije nedostatak podataka, već činjenica da kriteriji poput sigurnosti, brzine i prohodnosti rijetko idu ruku pod ruku – najkraća ruta rijetko je i najsigurnija. Ovaj rad polazi od teze da takav problem, neovisno o vrsti krize koja ga je pokrenula, ima jedinstvenu strukturu te da se za njega može razviti jedan opći sustav podrške odlučivanju temeljen na metodama višekriterijskog odlučivanja (MCDM). U fokusu su tri metode koje se u literaturi o kriznom upravljanju spominju najčešće – AHP, VIKOR i TOPSIS – čiji su matematički aparat, postupci rangiranja te prednosti i ograničenja detaljno raščlanjeni i ilustrirani na primjeru odabira evakuacijske rute. Kako bi se metode ispitale izvan statičnog, jednokratnog rangiranja, rad ih smješta u dinamičko, vremenski zahtjevno okruženje StarCraft II Learning Environment (SC2LE), gdje agent čije je odlučivanje vođeno MCDM metodama upravlja nizom strateških odluka pod pritiskom ograničenih resursa – okruženje strukturno analogno stvarnoj kriznoj situaciji, iako ne i identično njoj. Rezultati pokazuju da odabir MCDM metode nije neutralna tehnička pojedinost, već čimbenik koji izravno oblikuje ponašanje sustava: iste ulazne podatke tri metode pretvaraju u različite prioritete i različite odluke. Rad zaključuje kritičkim osvrtom na ograničenja simulacijskog pristupa i na sigurnosnu dimenziju automatiziranog odlučivanja u stvarnim kriznim situacijama, zagovarajući transparentnost sustava i zadržavanje čovjeka u petlji odlučivanja ondje gdje pogrešna preporuka može koštati ljudski život.

Ključne riječi

Višekriterijsko odlučivanje, krizno upravljanje, AHP, VIKOR, TOPSIS, hitna evakuacija, StarCraft II Learning Environment

ABSTRACT AND KEYWORDS

Abstract

When disaster strikes – an earthquake, flood, fire, or any other event threatening large numbers of people – the decision to evacuate must be made within minutes, on the basis of information that is almost always incomplete, contradictory, or already outdated. The difficulty is rarely a lack of data; it is that the criteria that matter most – safety, speed, and accessibility – rarely align, and the shortest route is rarely the safest one. This thesis argues that, regardless of the type of crisis that triggers it, this decision problem shares a common structure, and that a single, general decision-support system built on multi-criteria decision making (MCDM) methods can be developed for it. Three of the most widely documented methods in the crisis-management literature – AHP, VIKOR, and TOPSIS – are examined in depth, with their mathematical foundations, ranking procedures, and respective strengths and limitations illustrated through the problem of evacuation-route selection. To move beyond a static, one-off ranking exercise, the methods are tested within the dynamic, time-critical StarCraft II Learning Environment (SC2LE), where an agent whose decisions are driven by MCDM methods must manage a sequence of strategic choices under tight resource constraints – a setting structurally analogous to, though not identical with, a real crisis. The results show that the choice of MCDM method is no neutral implementation detail: given identical inputs, the three methods produce measurably different priorities and different behaviour. The thesis closes with a critical assessment of the limitations of the simulated approach and of the security dimension of automated decision-making in real crisis settings, arguing for system transparency and for keeping a human in the decision-making loop wherever a flawed recommendation could cost a human life.

Title

Multi-Criteria Decision Making Methods in Crisis Management

Keywords

multi-criteria decision making, crisis management, AHP, VIKOR, TOPSIS, emergency evacuation, StarCraft II Learning Environment

IZJAVA O KORIŠTENJU UMJETNE INTELIGENCIJE

U izradi ovog rada korišteni je Claude Pro, *Sonnet 5* (Anthropic, rujan 2026.) za:

- jezičnu lekturu i preformulaciju uvodnog poglavlja rada, uključujući usklađivanje strukture uvoda s poglavljima rada i preciznije razgraničenje između implementiranih metoda
- izradu popisa oznaka i kratica na temelju pregleda cjelokupnog teksta rada
- definiranje ključnih riječi na temelju pregleda cjelokupnog teksta rada
- izvlačenje i sažimanje bitnih informacija iz vanjske literature (npr. znanstvenih članaka) radi provjere relevantnosti i mogućnosti citiranja u radu
- uljepšavanje (formatiranje) programskog koda i pisanje/doradu komentara unutar koda, bez izmjene same logike i funkcionalnosti implementacije.

Sve generirane prijedloge autor je kritički ocijenio, prilagodio i uskladio sa stvarnim sadržajem provedenog istraživanja. Teorijska razrada MCDM metoda, implementacija eksperimentalnog sustava te programski kod izrađeni su samostalno, bez korištenja UI alata.